


Listas de conteúdos disponíveis em [ScienceDirect](#)

Computadores e Engenharia Industrial

Página inicial do jornal: www.elsevier.com/locate/caie

Um modelo de otimização multi-objetivo para um projeto de rede de fluxo generalizado confiável

Mina Dehghani ^a, Vahab Vahdat ^b, Maghsoud Amiri ^c, Elaheh Rabiei ^c, Seyedmohammad Salehi ^d, *^a Departamento de Gestão Industrial, Universidade Allameh Tabataba'i, Teerã, Irã^b Departamento de Engenharia Mecânica e Industrial, Northeastern University, Boston, EUA^c Universidade da Califórnia Los Angeles, Los Angeles, EUA^d Departamento de Ciências da Computação e da Informação, Universidade de Delaware, EUA

ARTICLE INFO

Palavras-chave:

Confiabilidade

Design de rede confiável

Otimização multi-objetivo

Rede de fluxo generalizado

NSGA-III

MOPSO

RESUMO

O projeto de uma rede confiável na presença de perda de fluxo tornou-se o objetivo principal dos projetistas de redes de hoje. No entanto, existem outros objetivos conflitantes importantes que dificultam o processo de projeto de rede eficiente. Este estudo propõe um modelo de otimização multi-objetivo para redes de fluxo de comunicação confiáveis, incluindo maximizar a confiabilidade da rede, minimizar o custo total e maximizar o fluxo da rede, simultaneamente. O custo total compreende o custo de construção de arcos de rede e o custo de fluxo, enquanto os arcos podem deixar de operar em capacidade total e funcionar apenas com uma fração de sua capacidade. O projeto de rede baseado em confiabilidade é modelado como uma programação linear inteira mista e resolvido por três métodos metaheurísticos multi-objetivos, a saber, otimização por enxame de partículas multi-objetivo (MOPSO) e duas versões de algoritmo genético de classificação não dominado (ou seja, NSGA-II e NSGA-III). Para selecionar a melhor solução de compromisso dos membros da frente de Pareto, um mecanismo baseado em fuzzy é utilizado. Por fim, para medir o desempenho dos três algoritmos, vários exemplos numéricos em pequena e grande escala são resolvidos. Os resultados computacionais indicam que o NSGA-III é superior ao MOPSO e ao NSGA-II em termos de taxa de convergência e tempo de execução, especialmente para problemas de grande escala. Um mecanismo baseado em fuzzy é utilizado. Por fim, para medir o desempenho dos três algoritmos, vários exemplos numéricos em pequena e grande escala são resolvidos. Os resultados computacionais indicam que o NSGA-III é superior ao MOPSO e ao NSGA-II em termos de taxa de convergência e tempo de execução, especialmente para problemas de grande escala. Um mecanismo baseado em fuzzy é utilizado. Por fim, para medir o desempenho dos três algoritmos, vários exemplos numéricos em pequena e grande escala são resolvidos. Os resultados computacionais indicam que o NSGA-III é superior ao MOPSO e ao NSGA-II em termos de taxa de convergência e tempo de execução, especialmente para problemas de grande escala.

1. Introdução

Na teoria dos grafos, uma rede é definida como uma série de nós que estão conectados uns aos outros por meio de arcos. As redes têm sido amplamente utilizadas para projetar e resolver problemas em diferentes campos, como transporte, cadeia de suprimentos e telecomunicações, com a intenção de transportar mercadorias / informações entre os nós para atender a um padrão de demanda-oferta distribuída. A topologia ou arquitetura de uma rede descreve como os nós são conectados por arcos. Por exemplo, um gráfico completo é uma rede totalmente conectada onde todos os nós são interconectados por arcos.

A indústria de telecomunicações tem visto vários avanços nas últimas décadas, continuando a melhorar tanto no hardware quanto na eficiência dos algoritmos subjacentes (Mousavi, Taghiabadi e Ayanzadeh, 2019). Redes sem fio modernas foram desenvolvidas com base em tecnologias de celular / Wi-Fi de alta velocidade e algoritmos de roteamento / agendamento muito eficientes, com capacidades de transporte de serviços sofisticados, incluindo voz, vídeo e dados com qualidade de serviço (QoS) diferentes requisitos (Esmailpour, Salehi, & Safavi, 2013; Salehi, Li, Shen,

Cimini e Graybeal, 2018) Com o aumento da demanda de dados, as novas redes tecnológicas precisam fornecer seus serviços com maior confiabilidade. Assim, é fundamental criar métodos computacionais eficientes para estimar a confiabilidade das redes tecnológicas. No entanto, mesmo para redes simplistas, pode ser mostrado que a maioria dos problemas de projeto confiáveis ideais são NP-completos (Provan & Ball, 1983). Consequentemente, encontrar uma solução ideal para o tamanho da rede realista em um período de tempo razoável ainda não foi alcançado (Larsson, 2014). Para estimar a solução ótima, abordagens como a teoria dos grafos, otimização, métodos de simulação e conceitos da teoria da probabilidade são usados para projetar as novas redes de comunicação.

Embora os problemas clássicos de rede presumam a preservação do fluxo na rede, em muitas aplicações reais, o fluxo não é conservado. Em vez disso, as redes generalizadas podem incorporar alguns níveis de ganhos ou perdas conforme o fluxo segue ao longo de um arco. Cada arco possui um multiplicador para representar a quantidade de ganhos e perdas. Como resultado, a rede generalizada pode ser aplicada para modelar sistemas de distribuição de fluxo nos quais a evaporação, erosão ou sedimento desperdiçariam o fluxo em alguns tubos. Por exemplo, nas redes da cadeia de abastecimento, os danos à carga em trânsito podem prejudicar o

* Autor correspondente.

Endereço de email: salehi@udel.edu (S. Salehi).<https://doi.org/10.1016/j.cie.2019.106074>

Recebido em 16 de dezembro de 2018; Recebido em versão revisada em 5 de setembro de 2019; Aceito em 17 de setembro de 2019 Disponível online em 01 de outubro de 2019

0360-8352 / © 2019 Elsevier Ltd. Todos os direitos reservados.

Nomenclatura		d_{eu}	grau de nó eu
Siglas		Notações de métodos de solução	
NSGA-II	Algoritmo Genético de Seleção Não Dominada-II Algoritmo	λ	Medida Lebesgue
NSGA-III	Genético de Seleção Não Dominada-III Otimização de Enxame	H	número de pontos de referência número de
PSO	de Partículas	n_o	funções objetivo
MOPSO	Otimização de Enxame de Partículas Multi-Objetivo Tempo	n_D	número de divisões em cada tamanho da população do eixo
NP	Polinomial Não Determinístico	n_P	objetivo
NOM	Número de membros de Pareto média	P_t	população na geração t
MID	distância ideal	Q_t	população de descendentes na geração t
HV_{eu}	Indicador de hiper-volume	R_t	população combinada e descendência na geração t
Notações de modelo matemático		M_{sto}	número máximo de iterações para cada metaheurística al- goritmo
s	nó de origem	F_{min}, F_{max}	valor mínimo e máximo do eu^o objetivo
t	nó coletor		função
$q_{eu,j}$	probabilidade de falha para arco (eu,j)	eu_{eu}	distância de eu^o Solução de Pareto do ponto ideal indivíduos de um nível
$CB_{eu,j}$	custo de construção do arco (eu,j)	D_{eu}	de compatibilidade de conjunto de soluções não dominadas
$CF_{eu,j}$	custo por unidade de fluxo no arco (eu,j)	μ	
$eu_{eu,j}$	limite inferior de fluxo no arco (eu,j)	P_m	probabilidade de mutação
$voc_{eu,j}$	limite superior de fluxo no arco (eu,j)	P_c	probabilidade de cruzamento
$uma'_{eu,j}$	fator de perda no arco (eu,j), $0 \leq uma'_{eu,j} \leq 1$	Δ	diversidade métrica
$uma_{eu,j}$	multiplicador de arco, calculado como $a = 1 - uma'_{eu,j}$	n	número de pontos de referência das
F_{no}	fluxo de entrada	UMA	soluções de Pareto
F_{fora}	fluxo de saída	$x_{k_{eu}}$	posição da partícula eu^o em iteração k^o
$x_{eu,j}$	variável de decisão binária para projeto de topologia de rede que é 1 quando há conexão entre eu e j , e é 0 caso contrário	$V_{k_{eu}}$	velocidade da partícula eu^o em iteração k^o
$f_{eu,j}$	variável de decisão contínua indicando a quantidade de fluxo no arco (eu,j)	C_{eu}	coeficiente de aprendizagem local em MOPSO coeficiente
$R(x)$	confiabilidade da rede	C_g	de aprendizagem global em taxa de mutação MOPSO em
$H(d)$	Limite superior de Jan	$\mu_{avaliar}$	MOPSO
		n_r	número de repositório em peso de inércia
		C	MOPSO em MOPSO
		C_{umido}	taxa de amortecimento de peso de inércia,

fluxo. Outro exemplo pode ser em sistemas de geração de energia, onde alguma perda de energia é inevitável para transferir eletricidade de um local para outro. Na verdade, os problemas de rede generalizados podem ser discernidos como o problema de fluxo máximo clássico com capacidade de modelar o fluxo de "vazamento".

Projetar uma rede ideal que seja econômica e confiável está surgindo como um exemplo de rede com bom desempenho. Neste estudo, formulamos e analisamos um modelo de otimização multiobjetivo para uma rede de fluxo generalizado confiável no que diz respeito aos objetivos conflitantes, incluindo simultaneamente maximizar a confiabilidade da rede, maximizar o fluxo da rede e minimizar o custo total. Uma vez que a complexidade computacional do modelo proposto torna impraticável ser resolvido por métodos exatos, três algoritmos metaheurísticos de vanguarda, a saber, algoritmo de otimização por enxame de partículas multi-objetivo (MOPSO) e algoritmo genético de classificação não dominado-II e III (NSGA- II e NSGA-III). Os resultados indicam a eficácia do procedimento de solução para resolver muitos problemas objetivos de otimização.

As principais contribuições deste artigo são resumidas da seguinte forma:

- Para projetar uma rede de comunicação realista, três objetivos conflitantes são considerados no modelo matemático. Enquanto maximizar a confiabilidade de uma rede é o objetivo principal desta pesquisa, a maioria das decisões não são feitas pela confiabilidade da rede em solitário. Além disso, a minimização do custo da rede e a maximização do fluxo da rede precisam ser consideradas para fornecer uma solução abrangente, porém robusta. Ao contrário de estudos anteriores que utilizam no máximo dois objetivos, esta pesquisa reconhece a importância de fluxo, custo e confiabilidade e desenvolve um modelo para otimizar simultaneamente três objetivos em uma plataforma. O custo total compreende o custo de

construção de arcos de rede e o custo do fluxo. A confiabilidade da rede é estimada pelo limite superior de Jan (Rong-Hong, 1993) que podem ser usados em redes de grande escala onde os métodos exatos não são viáveis. Finalmente, o fluxo da rede do nó fonte para o nó receptor é favorecido para ser maximizado enquanto os arcos têm diferentes

confiabilidades.

- A fim de decidir sobre a seleção da solução de compromisso anterior ou melhor da frente de Pareto, um mecanismo baseado em fuzzy é aplicado. Portanto, o modelo proposto leva a um projeto final de rede de fluxo generalizado confiável, que representa o compromisso desejado entre os diferentes objetivos do ponto de vista do tomador de decisão.

O resto do artigo está organizado da seguinte forma. Na seção seguinte, revisamos a literatura do estado da arte relevante para problemas de fluxo máximo / custo mínimo, problemas de fluxo de rede generalizados e projeto de rede confiável. Além disso, Seção 2 discute a aplicação de abordagens metaheurísticas na solução de problemas de rede, como otimização multi-objetivo usando MOPSO, NSGA-II e NSGA-III. Na seção 3 , fornecemos um resumo da declaração do problema com suposições subjacentes e o modelo matemático para redes de comunicação confiáveis. Na seção 4 , apresentamos uma descrição holística do procedimento de solução para NSGA-II, NSGA-III e MOPSO e ajuste de seus parâmetros principais. O desempenho dos métodos de solução propostos são avaliados posteriormente por exemplos numéricos na Seção 5 . Pontos fortes e limitações do modelo e métodos propostos são investigados na Seção 6 . Finalmente, Seção 7 conclui o artigo e sugere direções de pesquisas futuras.

tabela 1

Uma revisão da literatura relacionada a modelos de confiabilidade de rede.

Características	Estudos de pesquisa										
	Sivaree-ratana et al. (2002)	Konak e Smith (2011)	Lin e Chang (2013)	Sim (2013)	Kuipers et al. (2014) et al. (2015)	Elsheikrat (2015)	Sim (2015)	Zuev et al. (2015)			
Confiabilidade	Todos os terminais	✓				✓					
	Source-Sink			✓		✓	✓	✓			
	Fracasso	No Nó									
		No arco	✓	✓				✓	✓		
		Redutível em série paralela									
		Métodos de aproximação	✓	✓			✓		✓		
	Avaliação da confiabilidade	Limites superior / inferior	✓			✓	✓				
		Exclusão de Inclusão			✓			✓			
		Soma recursiva da confiabilidade disjunta do Quickest-path			✓	✓					
		Programação dinamica Determinístico	✓					✓			
Custo	Estocástico		✓								
	Multi-valor				✓						
	Fator de Transmissão										
	Custo de Fluxo										
	Custo fixo	✓									
	Dinâmico						✓	✓			
	Multiestado			✓	✓		✓	✓			
	Confiabilidade		✓	✓	✓						
	Objetivos	Fluxo		✓		✓	✓				
		Custo	✓	✓							
Heurística							✓				
Metaheurística		✓	✓			✓					
Solução	Híbrido										
	Simulação	✓	✓		✓	✓					
	Exato			✓	✓		✓	✓			
Características	Estudos de pesquisa										
	Pant et al. (2015)	El Khadri e Yeh (2016)	Mainrowski (2016)	Hochbaum (2016)	Jane e Laii (2017)	Sherman (2017)	Ruiwen et al. (2017)	Sim e Chu (2018)	Cancela et al. (2019)	Proposto modelo	
Confiabilidade		✓			✓		✓	✓	✓	✓	
	✓		✓				✓		✓	✓	
		✓			✓						
			✓					✓		✓	
Custo											
(Continua na próxima página)											

(Continua na próxima página)

Tabela 1 (continua)

Características	Estudos de pesquisa									Proposto modelo
	Pant et al. (2015)	El Khadiri e Yeh (2016)	Malinowski (2016)	Hochbaum (2016)	Jane e Laih (2017)	Sherman (2017)	Ruiwen et al. (2017)	Sim e Chu (2018)	Cancela et al. (2019)	
Rede		✓	✓		✓		✓	✓	✓	
Objetivos	✓	✓			✓		✓	✓	✓	✓
Solução	✓			✓				✓		✓

2. Revisão da literatura

Problemas de fluxo máximo em que o objetivo é transferir o fluxo máximo por meio da capacidade dos arcos têm sido estudados por diversos estudiosos. No entanto, investigar o efeito de deterioração do fluxo em arcos, ao invés da preservação do fluxo através da rede, torna esses modelos uma boa representação de muitos problemas reais, especialmente em redes de energia elétrica ou cadeias de suprimentos. [Sim \(2013\)](#) apresentou uma rede determinística de fluxo multiestado, considerando o efeito de deterioração. Os autores avaliaram a confiabilidade do modelo por um algoritmo de busca baseado em caminho. [Kuipers, Yang, Trajanovski e Orda \(2014\)](#) estudou um problema de fluxo máximo em redes estocásticas e usou um algoritmo baseado em otimização convexa para resolver o problema proposto. Os autores utilizaram uma distribuição de probabilidade log-côncava para atraso e largura de banda dos arcos. É mostrado em [Kuipers et al. \(2014\)](#) que aplicando uma restrição de atraso adicional, o problema se torna NP-difícil. [Jane e Lai \(2017\)](#) estudaram uma rede multi-estado em que não apenas capacidades multi-valorizadas e probabilidades de operação associadas foram consideradas, mas também o período de trânsito foi usado para ponderar os arcos. Eles apresentaram um algoritmo para calcular a distribuição de probabilidade do valor do fluxo máximo dinâmico.

Uma variação do problema de fluxo de custo máximo é minimizar o custo mínimo do fluxo. O objetivo no problema de fluxo de custo mínimo é enviar um determinado fluxo dos nós de suprimento para os nós de demanda com o menor custo, sujeito às restrições de capacidade do arco. Problemas de fluxo de custo mínimo também têm sido estudados excessivamente, tanto na aplicação quanto na teoria. [Hochbaum \(2016\)](#) explorou as ligações entre o problema de fluxo de custo mínimo e o problema de compensação de custo de tempo (TCF) no gerenciamento de projetos. A abordagem proposta resultou em algoritmos polinomiais mais rápidos para ambos os problemas. [Sherman \(2017\)](#) considerou um fluxo ilimitado com custo mínimo em gráficos não direcionados e apresentou um novo framework para otimizá-lo. Nessa estrutura, para obter solucionadores altamente precisos, eles combinaram solucionadores imprecisos disponíveis com pré-condicionamento não euclidiano. [Cohen e Megiddo \(1994\)](#) propôs o problema de transbordo generalizado não capacitado e o problema de circulação generalizada, e os resolveu por um algoritmo de aproximação iterativa. Eles também consideraram esses problemas em redes generalizadas bidirecionadas.

Outra propriedade importante do projeto de rede é a confiabilidade das redes que investigam a probabilidade de falha de seus componentes. [Malinowski \(2016\)](#) fornece uma pesquisa de confiabilidade em redes de computadores, rede de distribuição de água, sistemas de dutos e redes de distribuição de eletricidade. [Zuev, Wu e Beck \(2015\)](#) apresentou uma avaliação quantitativa para a confiabilidade do serviço de rede em um ambiente estocástico. Eles apresentaram um modelo para um problema geral de confiabilidade de rede e usaram modelos de simulação de subconjunto para calcular a confiabilidade do serviço. Então, pequenas probabilidades de falha de sistemas dinâmicos complexos foram calculadas usando a técnica Markov Chain Monte Carlo. [Lin e Chang \(2013\)](#) avaliou o desempenho de uma rede de manufatura de fluxo estocástico considerando as taxas de falha das estações. Devido à falha da estação, nem todas as demandas foram atendidas, e a probabilidade de realização da demanda foi considerada um indicador de desempenho. Portanto, os autores construíram um sistema de manufatura considerando as capacidades incertas com distribuições probabilísticas e as linhas de produção múltiplas. [Elshqeirat, Soh, Rai e Lazarescu \(2015\)](#) formar uma rede de comunicação com o objetivo de minimizar o custo, satisfazendo uma restrição de confiabilidade pré-condicionada. Para resolver o problema, os autores aplicaram uma abordagem de programação dinâmica. Como o problema foi demonstrado como NP-difícil, eles também propuseram três heurísticas gananciosas. Uma rede de fluxo com pontos de entrada, nós apenas de trânsito e pontos de fluxo de saída foi considerada por [Malinowski \(2016\)](#). Em sua rede, os arcos foram direcionados e os componentes foram reparados com falhas e taxas de reparo constantes. O indicador de desempenho foi definido como a razão entre a demanda total atendida e a demanda total desejada em todos os pontos de escoamento.

O problema de projetar uma rede que leve a confiabilidade em consideração é NP-difícil (Provan & Ball, 1983), e a literatura atual defende que métodos exatos só foram capazes de resolver pequenas redes

problemas de projeto com 15 ou menos arcos. Por sua vez, métodos aproximados e heurísticas têm sido geralmente utilizados para resolver problemas de projeto de rede confiável. Sim (2015) desenvolveu um algoritmo aproximado com base na primeira pesquisa em profundidade (DFS) para resolver uma rede de fluxo de múltiplos estados de modo que o fluxo líquido para dentro e para fora de um nó fosse definido como zero. Este algoritmo encontrou todos os caminhos mínimos e removeu todas as candidatas inviáveis do problema de confiabilidade do caminho mínimo. Srivaree-ratana, Konak e Smith (2002) estimou a confiabilidade da rede de todos os terminais usando uma rede neural artificial. Eles desenvolveram e treinaram redes neurais com base na confiabilidade de todos os terminais de topologias de rede e responsabilidades de arco.

Para redes maiores, técnicas metaheurísticas têm sido utilizadas. Metaheurísticas são procedimentos de busca de alto nível que fornecem aproximações de solução suficientemente boas para problemas de otimização em grande escala. Exemplos de metaheurísticas aplicadas à confiabilidade em projetos de rede são algoritmos genéticos (Deeter & Smith, 1997), recocimento simulado (Suman, 2003), pesquisa tabu (Beltrán & Skorin-Kapov, 1994), e algoritmos de colônia de formigas (Watcharasitthiwat & Wardkein, 2009). O projeto de redes de comunicação confiáveis com o objetivo de minimizar o custo com arcos bidirecionais foi considerado pela primeira vez por Dengiz e Smith (2000). Eles usaram algoritmo genético com foco nos custos e confiabilidade dos arcos. Para formar uma rede de telecomunicações confiável com conectividade de dois nós Konak e Smith (2011) desenvolveu um algoritmo genético bi-objetivo, que englobava três métodos de um método exato para calcular a confiabilidade, uma técnica de estimativa de Monte Carlo e um limite superior para a confiabilidade de todos os terminais de redes com confiabilidade de arco opcional. Deb, Agrawal, Pratap e Meyarivan (2000) desenvolveram o algoritmo genético de classificação não dominado-II (NSGA-II) e, posteriormente, eles utilizaram um algoritmo genético de classificação não dominado rápido em Deb, Pratap, Agarwal e Meyarivan (2002) que evita a perda de boas soluções e é eficiente em termos de taxa de convergência e diversidade. Em 2014, uma versão estendida do algoritmo NSGA-II (chamado NSGA-III) é proposta por Deb e Jain (2014), capaz de resolver problemas com muitos objetivos de forma eficiente. Alguns exemplos deste método no campo da aplicação de confiabilidade podem ser encontrados em (Li, Mobin e Keyser, 2016; Mobin, Li e Komaki, 2017). Otimização de enxame de partículas bi-objetivo multi-objetivo foi usada por

Xu, Tu e Zeng (2012) para resolver um problema de fluxo de rede de custo mínimo usando um modelo não linear multi-objetivo de dois níveis. O nível superior minimiza os custos diretos e de tempo de transporte e o nível inferior minimiza os custos de transporte. Pant, Kumar, Kishor, Anand e Singh (2015) propôs um problema de otimização de confiabilidade com dois objetivos conflitantes de maximizar a confiabilidade do sistema e, ao mesmo tempo, minimizar os custos associados. Para resolver o modelo, eles desenvolveram um algoritmo evolutivo multiobjetivo, ou seja, uma otimização de enxame de partículas que considera a distância de aglomeração para selecionar soluções de fronteira.

A fim de melhor classificar a literatura mais recente relativa a problemas de otimização de confiabilidade de rede e demonstrar a lacuna preenchida por esta pesquisa, tabela 1 é fornecido. Estudos anteriores são classificados com base em métodos e tipos de avaliação de confiabilidade, modelagem de fluxo de rede, considerações de custo, tipos de rede, funções objetivas e metodologias de solução. Como os arcos são mais vulneráveis a falhas do que os nós, a maioria da literatura revisada, semelhante a esta pesquisa, considerou a confiabilidade fonte-dissipador e a falha a ser ocorrida nos arcos. Os métodos populares de avaliação da confiabilidade da rede são: métodos de aproximação, confiabilidade do caminho mais rápido e limites superior-inferior. Em termos de tipos de fluxo, tanto os fluxos determinísticos quanto os estocásticos foram estudados em pesquisas anteriores, no entanto, esta pesquisa utiliza a transmissão no modelo de fluxo determinístico que permite que uma fração da capacidade do arco de transmitir o fluxo.

Em termos de custo, poucos estudos consideraram simultaneamente o custo do fluxo (custos variáveis) e o custo de construção da rede (custos fixos), sendo que ambos os custos são importantes nas decisões estratégicas e táticas de qualquer rede. A revisão da literatura acima indica que nenhum estudo foi realizado para projetar redes de comunicação que considerem custo, fluxo e confiabilidade simultaneamente e, posteriormente, um efetivo

algoritmo de otimização, como NSGA-III, não foi customizado para este propósito. Os objetivos e outras características do modelo resultaram em um modelo genérico que pode ser usado para diferentes classes de redes, como redes de telecomunicações, redes de transporte, redes mecânicas (Guo, Li e Jin, 2018; Jian, Zhaojun e Keyser, 2018; Lin & Yeh, 2015) e redes de energia elétrica (redes de energia).

3. Descrição do problema

Três critérios importantes no projeto de redes sustentáveis são confiabilidade, custo e quantidade de fluxo para o transporte. A importância de projetar redes confiáveis é mais explícita para redes de infraestrutura, como redes de computadores, tráfego e redes de energia (Namin, Kamarthi, Eckelman e Isaacs, 2019). Da mesma forma, interrupções nas redes da cadeia de abastecimento, como cadeias farmacêuticas, podem ameaçar a vida de muitos pacientes necessitados (Azghandi, Griffin e Jalali, 2018). Qualquer interrupção ou falha nas redes de infraestrutura pode levar a eventos catastróficos imprevistos, tanto durante a interrupção quanto após a recuperação da rede. Em muitas dessas redes, a estabilidade e sustentabilidade da rede são avaliadas de forma consistente e com o auxílio da manutenção preventiva, a confiabilidade da rede é mantida em alto nível.

Dependendo da importância da confiabilidade da rede, em geral dois critérios principais para redes confiáveis são considerados, a saber, *terminal completo* e *fonte-sumidouro*. A confiabilidade de todos os terminais concentra-se na capacidade de comunicação entre todos os nós da rede por meio de alguns caminhos não identificados. A confiabilidade fonte-coletor se concentra na capacidade de um nó de origem predefinido de se comunicar com um nó de coletor predefinido por meio de alguns caminhos não identificados. Este artigo considera apenas a confiabilidade source-sink, uma vez que é mais generalizável para redes de grande escala. Uma aplicação dessas redes são as redes de computadores, nas quais um usuário (nó de origem) está interessado em se conectar a um servidor (nó de coletor). Embora não haja necessidade de todos os nós internos se comunicarem com outros nós, um caminho indefinido entre os nós de origem e coletor deve estar disponível.

Uma área significativa de pesquisa em problemas de projeto de rede é a estimativa da confiabilidade da rede. Em geral, quatro métodos amplamente utilizados para avaliar a confiabilidade da rede são: (1) Avaliação exata usando métodos analíticos (processo único e paralelo) (Nguyen, Vo e Vu, 2016), (2) Estimativa usando métodos de aproximação, como simulação de Monte Carlo (Chen, 2017; Gertsbakh e Shpungin, 2016; Praks, Kopustinskas e Masera, 2017), (3) Encontrar limites superiores ou inferiores (Jan, Hwang e Chen, 1993; Srivaree-ratana et al., 2002), e (4) Encontrar um substituto bruto (Dubourg, Sudret, & Deheeger, 2013; Konak & Smith, 2006). Nesta pesquisa, o método do limite superior de Jan (Rong-Hong, 1993) é usado para estimar a confiabilidade da rede.

3.1. Formulação do modelo matemático

Neste artigo, o problema de projeto de rede de fluxo generalizado confiável é modelado como um modelo matemático linear inteiro misto multi-objetivo. O modelo proposto determina um projeto de rede ótimo considerando ganhos e perdas do fluxo através da rede em relação aos objetivos conflitantes, ou seja, minimizar o custo total do sistema e maximizar o fluxo e a confiabilidade.

As seguintes suposições são feitas no modelo matemático proposto: (1) A probabilidade de falha de cada arco é independente das falhas de outros arcos. (2) Os custos e a probabilidade de falha dos arcos são conhecidos e determinísticos. (3) Os arcos estão ativos e operacionais se não falharem e a opção de reparo não for considerada no modelo. (4) Em uma rede ótima, o fluxo passará apenas por arcos ótimos, portanto, pode haver arcos sem fluxo. (5) Os fatores de perda e transmissão de arcos diferentes são variáveis aleatórias estatisticamente independentes e são números positivos reais.

Dado um gráfico direcionado $G(N, A)$ Onde $N = \{1, \dots, n\}$ denota o conjunto de nós incluindo a fonte (s) e nó coletor (t), e UMA denota o conjunto de arcos possíveis. Cada arco (eu)

$$\in UMA \text{ tem probabilidade de falha } 0 \leq q_{eu} \leq 1$$

Assumimos que a probabilidade de falha para todos os arcos são semelhantes durante

cada cenário, portanto q é usado em vez de $q_{eu,j}$ para uma interpretação mais fácil. Deixe

$CB_{ij} > 0$ denota o custo de construção do arco (eu, j) . Exemplos de tais custos são custos de material, custos de conexão e terminais, custos de instalação como descascamento e aterro e nivelamento, custos de terreno ou direito de passagem inerentes ao cabeamento. Visto que a maioria desses itens são "custos unitários", o custo total de um arco pode ser estimado pelo comprimento do arco.

Contudo,

por uma questão de simplicidade, $CB_{eu,j}$ é assumido fixo por arco neste modelo.

$CF_{ij} > 0$ indica o custo por unidade de fluxo através do arco (eu, j) . A quantidade permitida de fluxo junto (eu, j) deve ser pelo menos igual ao fluxo

limite inferior (eu, j) e no máximo igual ao limite superior (eu, j) . Aqui, os limites inferiores em todos os fluxos de arco são zero. Além disso, deixe $uma_{eu,j}$ denota fator de perda

sobre $(eu, j) \in UMA$. Então, o multiplicador de arco, representado por $uma_{eu,j}$ é o fator de transmissão.

Observe que se $uma_{eu,j}$ é igual a 1, uma rede pura ou convencional para-

mulação existe; E se $uma_{eu,j} > 1$, o fluxo é aumentado (ganho); e se $uma_{eu,j} < 1$,

o fluxo é diminuído (perda). Além disso, neste problema, F_{no} denotam o fluxo de entrada e o fluxo de saída, respectivamente. Observação no e F_{fora} aquele fluxo $o C$ conservação pode não alcançar neste modelo, uma vez que F_{no} não é necessariamente igual a F_{fora} . Isso se deve a ajustes de fluxo causados pela transmissão

fator. Finalmente, $x_{eu,j}$ e $f_{eu,j}$ são variáveis de decisão binárias e contínuas,

respectivamente. Se arco (eu, j) está incluído no design ideal, $x_{eu,j}$ é igual a

1 e 0 caso contrário. A quantidade de fluxo ao longo do arco (eu, j) é indicado por

$f_{eu,j} \in \mathbb{R}^+$. X é a topologia de arco de $x_{12}, \dots, x_{eu,j}, \dots, x_{N1}$. $N \in R(X)$ é a confiabilidade de X . A programação linear inteira mista multi-objetivo

modelo pode ser formulado da seguinte forma:

$$\max R(X) \quad (1a)$$

$$\max F_{out} = \sum_{eu} \sum_j f_{eu,j} \quad (1b)$$

$$\min \sum_{eu} \sum_j CB_{eu,j} x_{eu,j} + \sum_{eu} \sum_j CF_{eu,j} f_{eu,j} \quad (1c)$$

sujeito a

$$\sum_j f_{sj} - \sum_{js} af_{js} \leq F_{no} \quad (1d)$$

$$\sum_j f_{eu,j} - \sum_j uma_{eu,j} f_{ej} = 0, \quad \forall eu, eu \neq \{s, t\} \quad (1e)$$

$$\sum_j f_{ij} - \sum_j uma_{ij} f_{ji} = F_{fora} \quad (1f)$$

$$f_{eu,j} \leq f_{eu,j} \leq voc_{eu,j} x_{eu,j}, \quad \forall (eu, j) \quad (1g)$$

$$\sum_j x_{eu,j} \leq \sum_j x_{eu,j} \leq d_{eu}, \quad \forall i = \{1, \dots, n\}, eu \neq j \quad (1h)$$

$$R(X) \leq \left[H(d) \cong 1 - \left[\sum_{eu} q_{di} \times \prod_{k=1}^{mi} (1 - q_{dk}) \right] \right] \quad (1i)$$

$$f_{eu,j} \in \mathbb{R}$$

$$x_{eu,j} \in \{0, 1\} +$$

$$d_{eu} \in \mathbb{Z}$$

Para projetar uma rede, escolhendo um subconjunto dos arcos potenciais, a confiabilidade da rede, denotada em (1a), e o fluxo de saída (a quantidade real de fluxo de s para t), denotado na Eq. (1b), precisam ser maximizados. Ao mesmo tempo, o custo total incluindo os custos totais de construção e os custos totais de fluxo, denotados em (1a), deve ser minimizado. No entanto, esses objetivos estão em conflito um com o outro; custo e confiabilidade são os dois objetivos conflitantes e a compensação entre eles não é linear. Aqui, assumimos que a confiabilidade tem um custo mais alto com um

variam de 0 a 1, representando o espectro entre um estado não operacional e um estado totalmente confiável. Além disso, presumindo o custo de um fluxo, o fluxo máximo é mais caro para transportar através da rede. Nesta pesquisa, as soluções ótimas de Pareto são obtidas a partir do conjunto de trade-offs ótimos entre os objetivos conflitantes. As soluções ótimas de Pareto são o conjunto de soluções em que nenhum dos objetivos pode ser melhorado sem degradar pelo menos um dos outros objetivos.

Para mostrar possíveis desequilíbrios entre a quantidade de fluxos que entram e saem de um arco, os fluxos de uma rede generalizada são multiplicados por fatores de ganho / perda no conjunto de restrição (1d), (1e) e (1f). O fluxo em cada arco não pode exceder os limites inferior e superior especificados implícitos pelo cenário, conforme definido na restrição (1g). Também garante que, para arcos não selecionados, o fluxo permaneça zero. Eq. (1h) calcula o grau

de cada nó eu , denotado como d_{eu} , que é o número de arcos de entrada e saída conectados a cada nó. Utilizando o grau de nós, con-

tensão (1i) mostra o limite superior de Jan que é usado para estimar a confiabilidade da rede onde q é a falta de confiabilidade dos links, e

$mi = \text{mente}_{eu, eu} - 1$). Encontrar o limite superior da confiabilidade da rede pode ser

transformado para encontrar uma rede com sequência de graus (d_1, d_2, \dots, d_n) tal

que $H(d)$ é maximal e $\sum_{i=1}^n d_i = 21$ segura onde eu denota total

número de arcos na rede. Em outras palavras, cada rede também pode

ser associada a uma sequência única de grau chamada de sequência de grau. Por exemplo, Figura 1 mostra

a sequência de graus para um gráfico de amostra. Para usar o método do limite superior de Jan,

duas condições são necessárias para a rede: (1) O gráfico deve ser conectado, ou seja, a rede não é

dividida em várias partes. (2) Cada nó deve estar associado a pelo menos dois outros nós (condição

de duas conectividade) para que em caso de falha de uma borda, o nó não fique isolado e possa

manter sua conexão com a rede. Essas duas condições são consideradas na função objetivo de

confiabilidade como uma função de penalidade. O pseudo-código relacionado a este requisito está

incluído em Apêndice A.

4. Procedimento de solução

A complexidade computacional tem sido uma barreira para muitos problemas de grande escala.

Muitos problemas de otimização do mundo real pertencem à classe de NP-hard e quando o tamanho

do problema aumenta, não há um método analítico exato para resolvê-los em tempo eficiente.

Portanto, algoritmos metaheurísticos são aplicados como ferramentas eficientes para otimizar essa

classe de problemas. O problema de confiabilidade do projeto de rede é um problema de otimização

combinatória NP-difícil (Garey, 1979; Provan & Ball, 1983). Portanto, os algoritmos metaheurísticos

são bons candidatos para lidar com tais problemas. Embora existam vários métodos metaheurísticos

que podem ser aplicados a problemas multi-objetivos, utilizamos e comparamos três algoritmos, a

saber MOPSO, NSGA-II, NSGA-III. As diferenças entre esses métodos e sua força para lidar com

problemas multiobjetivos levaram à seleção desses métodos. Embora os métodos NSGA e MOPSO

sejam metaheurísticas baseadas em população, a diferença está na seleção e classificação dos

procedimentos de soluções frontais de Pareto. Mais especificamente, NSGA-III utiliza pontos de

referência para classificar o




Figura 1. Gráfico de amostra com 8 nós representando o problema estudado. Observe que s representa o nó de origem e t denota o nó coletor. As linhas sólidas representam arcos selecionados ($x_{ij} = 1$). A sequência de graus para cada rede é diferente. e gráfico da direita, A sequência de graus é $\{2, 2, 4, 2, 3, 2, 2, 3\}$ e $\{3, 2, 3, 3, 2, 2, 3, 2\}$ para a esquerda respectivamente.

soluções, enquanto MOPSO usa mecanismos probabilísticos, como seleção de roda de roleta. Assim, os dois procedimentos metaheurísticos são distintos e podem fornecer mais informações sobre os resultados computacionais. Enquanto isso, com base na literatura existente, MOPSO tem se mostrado um método eficiente e rápido para resolver problemas de programação inteira mista em grande escala (Bagherinejad e Dehghani, 2016; Pasandideh, Niaki e Sharafzadeh, 2013). O PSO incorpora a inteligência de enxame que alavanca a precisão e a velocidade de convergência para as melhores soluções. Na inteligência de enxame, não apenas a experiência de cada partícula envolve a descoberta da próxima solução, mas também o comportamento social de todas as outras partículas simula neste procedimento. Além disso, PSO é uma metaheurística, pois faz poucas ou nenhuma suposição sobre o problema que está sendo otimizado e pode pesquisar espaços muito grandes de soluções candidatas.

4.1. Descrição NSGA

Algoritmo Genético (GA) é um algoritmo de busca baseado em população que tem sido amplamente utilizado para resolver problemas de otimização em larga escala em diferentes domínios. No entanto, ele só pode ser utilizado para problemas de otimização de objetivo único. Uma extensão do algoritmo GA para problemas de otimização multi-objetivos é chamada NSGA-II ou The Non-Dominated Sorting Genetic Algorithm-II. Foi proposto pela primeira vez por Deb et al. (2000, 2002), onde um conjunto de soluções de frente de Pareto são eficientemente selecionadas, restringidas por múltiplas funções objetivo. Para este propósito, o NSGA-II, semelhante ao GA, emprega um conjunto de operadores bioinspirados com substitutos, incluindo seleção, cruzamento e mutação. Neste artigo, cada membro da população em NSGA-II é uma matriz de estrutura que carrega a posição dos membros, solução, custo, classificação, conjunto de dominação, contagem dominada e distância de aglomeração. O Posição é um zero / um

$N \times N$ matriz de adjacência, que demonstra a conexão entre cada par de nós, onde N é o número de nós. O Custo inclui três valores de função objetivo, ou seja, confiabilidade (1a), custo total (1b), e fluxo máximo (1c). O Solução contém a matriz de fluxo, as violações e se a solução é viável ou não. O Ranking indica a classificação da solução. O Conjunto de Dominação inclui o conjunto de membros da população, dominado pela solução. O Conde dominado

retém a frequência de vezes que a solução foi dominada por outra solução durante o processo de pesquisa. Como resultado, para a solução ótima de Pareto, o Conde dominado deve ser zero. O último componente apresenta o distância de aglomeração que mede a densidade populacional em torno de uma solução pela distância média da solução com duas soluções vizinhas (Konak, Coit, & Smith, 2006). No NSGA-II, o distância de aglomeração é usado em uma técnica de seleção chamada torneio lotado, onde o operador de seleção usa dominância e distância de crowding como critérios de seleção primários e secundários.

O encontro simultâneo com muitos objetivos (mais de dois) é uma das características proeminentes do NSGA-III. Este algoritmo foi proposto por Deb e Jain (2014) por alteração dos operadores de seleção do NSGA-II, em que um ou um conjunto de pontos pré-especificados são considerados pontos de referência. As etapas do algoritmo são as seguintes (Bhesdadiya, Trivedi, Jangir, Jangir e Kumar, 2016):

4.1.1. Designação de pontos de referência em um hiperplano para NSGA-III

Uma abordagem para garantir a diversidade () das soluções geradas é determinar um conjunto de pontos de referência. No NSGA-III, vários pontos são colocados em um hiperplano normalizado, onde têm direção idêntica em todos os eixos. O número de pontos de referência (H) é calculado por:

$$H = \left\lceil \frac{n_D}{n_D - 1} \right\rceil \quad (2)$$

Onde n_D é o número de funções objetivo, e n_D é o número de divisões a serem consideradas em cada eixo objetivo (por exemplo, para um problema com funções de três objetivos e cinco divisões, 21 pontos de referência são necessários). Os membros de Pareto serão associados aos pontos de referência gerados no hiperplano.

4.1.2. Operadores genéticos

Usando cross-over e mutação, novas soluções (ou seja, filhos) são geradas em cada iteração do NSGA-III. Por fazer igual importância entre todos os membros da população, o tamanho da população (n_P) é considerado próximo ao número de pontos de referência (H). Assim, em uma geração t , todo membros da população (P_t) converter em soluções não dominadas usando o mesmo método de classificação do NSGA-II. Depois disso, cada P_t gera novo população infantil (Q_t) por mutações e operadores de recombinação em que cada membro da população associado a cada ponto de referência e qualquer operador de seleção irá autorizar um concurso a ser definido entre vários pontos de referência. Então, uma população combinada ($R = P_t \cup Q_t$) é organizado e o mecanismo de classificação não dominado é realizado para seleccione a nova geração.

4.1.3. Normalização dos membros da população

Para determinar um ponto ideal da população atual, o mínimo de cada função objetivo ($F_{min}, i = \{1, 2, \dots, n_D\}$) deve ser identificado. Em seguida, cada função objetivo será movida subtraindo $Z_{min} = (F_{min}^1, F_{min}^2, \dots, F_{min}^{n_D})$ para a população atual. Então, um hiperplano de referência será criado pelas etapas não) para a população atual. Como os pontos de referência e as funções têm escalas diferentes neste problema, eles devem ser normalizados.

4.1.4. Associação entre pontos de referência e membros da população

Nesta fase, deve haver uma associação entre os membros da população e os pontos de referência. Aqui, uma linha de referência é desenhada conectando o ponto de referência e o ponto de origem. A seguir, a distância perpendicular entre cada solução e cada linha de referência é calculada. Finalmente, o ponto de referência que tem a menor distância da linha de referência de um membro da população está associado a esta solução.

4.1.5. Processo de preservação de nicho

Usando a distância perpendicular da linha de referência, a solução que tem a menor distância do ponto de referência deve ser mantida. Figura 2 mostra uma representação gráfica das etapas NSGA-III. Para utilizar NSGA-III neste problema, cada membro da população é uma estrutura de matriz com estas informações associadas: Posição, custo, solução, classificação, conjunto de dominação, contagem dominada, custo normalizado, referência associada, distância até a referência associada. Definição de Posição, custo, solução, conjunto de dominação e contagem de dominação é semelhante à descrição fornecida para NSGA-II. Uma Classificação

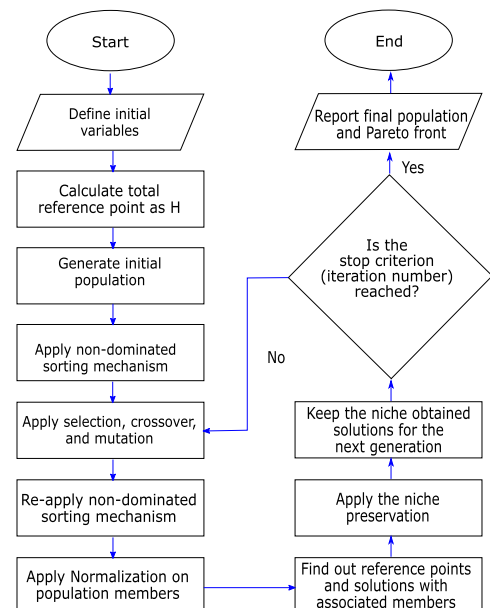


Figura 2. Representação gráfica do NSGA-III.

é definido para cada nível de frente com base em seu nível de não dominação. A solução que não é dominada por nenhum dos cromossomos é atribuída ao nível 1. O nível 2 é o nível secundário no qual o cromossomo é dominado por alguns cromossomos apenas no nível 1 e assim por diante. Observe que, embora o NSGA-II e o NSGA-III utilizem classificação, a função e o resultado subjacente são diferentes. O *Custo Normalizado* inclui valores normalizados de função objetivo (ver (Deb & Jain, 2014)). Após normalizar cada objetivo, cada membro da população é associado a um ponto de referência. Para este propósito, uma linha de referência é definida conectando cada ponto de referência no hiperplano com a origem. Então, a distância perpendicular (*Distância até a referência associada*) de cada membro da população de cada uma das linhas de referência é calculado. O ponto de referência com a menor distância de sua linha de referência para uma solução está associado com a solução (*Ref. Associada*).

4.2. Otimização de enxame de partículas multiobjetivo (MOPSO)

Semelhante ao GA, o algoritmo de Otimização de Enxame de Partículas (PSO) é outro algoritmo metaheurístico de objetivo único baseado em população que foi amplamente usado para problemas com domínio de solução de espaço contínuo (Kennedy & Eberhart, 1995). No PSO, uma população de soluções candidatas é chamada de "partícula". Onde cada partícula voa sobre o espaço de solução carregando cinco propriedades individuais: (1) posição atual, (2) velocidade da corrente, (3) valor da função objetivo correspondente à posição, (4) a melhor posição que foi alcançada pela partícula (melhor solução local), e (5) o valor da função objetivo correspondente à melhor posição da partícula. A velocidade e a posição de cada partícula serão atualizadas a cada iteração, influenciadas pela melhor solução local para cada partícula e pela melhor solução global entre todas as partículas.

Uma extensão do PSO para atender a problemas multi-objetivos é chamada de MOPSO (PSO Multi-objetivo). MOPSO tem um "repositório" (Coelho, Pulido e Lechuga, 2004) como um arquivo externo de soluções, incluindo as soluções não dominadas. Os membros do repositório fornecem uma aproximação do Pareto real frente ao problema de otimização. O pseudocódigo de MOPSO é ilustrado em Algoritmo 1.

Algoritmo 1

Pseudocódigo de etapas MOPSO.

```

Iniciale o enxame contendo n P partículas Avalie
partículas
Especifique soluções não dominadas e armazene-as no repositório
enquanto as condições de parada não foram satisfeitas Faz
    pra cada partícula do enxame Faz
        Selecione o líder para as partículas selecionadas
        Atualizar a velocidade de acordo com a regra de atualização de velocidade
        Atualizar a posição de acordo com a regra de atualização de posição Avaliar as
        funções objetivo para a partícula Aplicar mutação

        Atualize a melhor posição com base na nova posição:
        E se nova posição domina melhor anterior então
            substitua o melhor
        mais se a nova posição é dominada pelos melhores anteriores então
            mantenha o melhor
        outro
            escolha aleatoriamente um deles como o melhor
        fim se
    fim para
    Adicionar as partículas não dominadas ao repositório Remover
    membros dominados do repositório
terminar enquanto
  
```

4.2.1. Refinamento MOPSO

A maioria dos algoritmos de otimização de enxame de partículas são projetados para o domínio do espaço de busca contínuo. Nesta pesquisa, desde o trabalho variáveis $x_{eu,j} \in \{0, 1\}$ são discretos, velocidade de partícula e limites de posição converte o conjunto de soluções do domínio contínuo em valores discretos. Essa conversão se aplica a cada iteração, antes que esses valores sejam

usado para atualizar a localização da solução da próxima partícula.

Cada membro da população é modelado como uma matriz de estrutura com campos: *Posição, Solução, Velocidade, Custo, Melhor solução, Dominada (T / F), Índice de Grade e Subíndice de Grade*. O *Posição, Custo*, e *Solução* as definições são semelhantes à descrição fornecida para NSGA-II. O *Melhor solução* mantém a melhor posição e seu valor objetivo explorado até o momento pela partícula. Se uma partícula é dominada por outras partículas, *Dominado* sinalizador será verdadeiro, caso contrário, permanecerá falso. No algoritmo MOPSO, o espaço objetivo é tabulado, de modo que as duas propriedades, *Índice de grade* e *Grid Sub Index*, são usados para localizar cada partícula. Se um único número estiver nas casas da mesa, ele será mostrado com um *Índice de grade* e se dois números estão em casas de mesa, o número da linha e da coluna, *Grid Sub Index* é usado. Por exemplo, em um espaço objetivo bidimensional, GridIndex pode ser alcançado através do número de linhas e colunas (GridSubIndex) com

a $(m - 1) + j$ equação de mapeamento na qual, m é o número de linhas, eu e j são contadores de linhas e colunas.

4.3. Ajuste de parâmetro

A eficiência e a velocidade de convergência computacional dos métodos metaheurísticos são altamente dependentes do ajuste preciso dos componentes e parâmetros dentro desses métodos (Tatsis e Parsopoulos, 2019). No entanto, foi demonstrado que não há um conjunto de parâmetros genéricos que podem ser utilizados para qualquer um dos métodos metaheurísticos (Talbi, 2009).

A maioria dos métodos de ajuste dos parâmetros dentro de algoritmos metaheurísticos pode ser classificada na *conectados e desligada* métodos (Fallahi, Amiri e Yaghini, 2014). Na abordagem online, os parâmetros são atualizados de forma dinâmica ou adaptativa durante a execução da metaheurística (Akbaripour e Masehian, 2013). Este método é eficiente quando o número de parâmetros de ajuste é muito limitado. No ajuste de parâmetros off-line, para cada parâmetro um conjunto de valores é indicado na literatura ou em experimentos empíricos. Correspondentemente, a metaheurística é executada com os valores fixos para os parâmetros e os resultados são comparados para encontrar o melhor conjunto de parâmetros. Na maioria dos métodos offline, o designer da metaheurística ajusta cada parâmetro individualmente, também chamado de estratégia de otimização sequencial. Correspondentemente, as interações potenciais entre os parâmetros são negligenciadas e não é possível encontrar as configurações ideais ou quase ideais.

Design of Experiment (DOE) é uma das abordagens estatísticas bem estudadas para avaliar as interações entre os parâmetros (Ozkan, Ermis e Bekmezci, 2019). Uma vez que o número de parâmetros de ajuste e seus níveis de valor associados tomam-se grandes, os métodos DOE não são mais capazes de fornecer o valor dos parâmetros de melhor ajuste em tempo hábil. Como resultado, neste estudo, o método de Taguchi, também chamado de matriz ortogonal (Roy, 2001), uma alternativa ao design experimental completo no DOE, são utilizados para ajuste de parâmetro no modo offline. O projeto Taguchi requer um número muito menor de experimentos em comparação ao DOE e encontra as melhores soluções sem perda de generalidade.

4.3.1. Projeto Taguchi para ajuste de parâmetro

Para cada algoritmo metaheurístico implementado, vários parâmetros devem ser totalmente calibrados antes da execução final. Para tanto, três valores iniciais para cada parâmetro desconhecido são extraídos da literatura. Usando o software Minitab, o método Taguchi é utilizado para construir um projeto associado, correspondendo ao número de parâmetros que precisam ser ajustados simultaneamente e ao número de níveis para cada parâmetro. Utilizando um conjunto de níveis de parâmetros propostos em cada projeto, os resultados dos métodos metaheurísticos são calculados e então combinados usando o desvio percentual relativo (RPD), como medida de precisão. Como resultado, o melhor conjunto de parâmetros é derivado e utilizado para resolver nosso problema. Mais especificamente, para cada NSGA-II e NSGA-III, em eu 9 (3 4) O projeto Taguchi é usado, correspondem a quatro parâmetros, cada um com três níveis. Nestes algoritmos, tanto os parâmetros genéticos como os parâmetros de condição de terminação são investigados. Os quatro

Ajuste de parâmetro para NSGA-II, NSGA-III e MOPSO. Para cada parâmetro, três níveis são considerados e a interação entre os parâmetros é avaliada usando o método de Taguchi. Os valores finais dos parâmetros são indicados em negrito.

Parâmetros	NSGA-II			NSGA-III			MOPSO		
	nível baixo	nível base	alto nível	nível baixo	nível base	alto nível	nível baixo	nível base	Alto nível
tamanho da população (n)	150	250	350	150	200	250	150	200	250
Iterações máximas (M)	200	500	1000	200	500	1000	200	500	1000
Probabilidade de cruzamento (P_c)	0,7	0,8	0,9	0,7	0,8	0,9	-	-	-
Probabilidade de mutação (P_m)	0,1	0,2	0,3	0,1	0,2	0,3	-	-	-
Número do repositório (n_r)	-	-	-	-	-	-	100	150	200
Taxa de mutação (μ)	-	-	-	-	-	-	0,2	0,3	0,5
Aprendizagem local (μ_{local})	-	-	-	-	-	-	0,5	1,5	2
Coefficiente de aprendizagem global (μ_{global})	-	-	-	-	-	-	0,5	1,5	2
Peso de inércia (C)	-	-	-	-	-	-	0,4	0,7	0,9

parâmetros que são ajustados são *probabilidade de mutação* (P_m), *probabilidade de cruzamento* (P_c), *número de funções objetivas* são medidas por diferentes escalas de unidade (Niimura & Nakashima, 2003) Para desenvolver um método de solução que apresente um bom compromisso entre os objetivos, aplicamos um mecanismo fuzzy. Conforme mostrado a seguir, uma função de pertinência linear simples é considerada para cada uma das funções objetivo:

(n), **mesa 2** mostra o valor inicial e finalizado para parâmetros calibrados em NSGA-II e NSGA-III.

Em relação a outro parâmetro μ do NSGA-III, para um três objetivos

problema, os desenvolvedores do MOEA / D sugerem o número de divisões (n)

sobre cada o = bjetivo ser $n = 18$ (Bhesdadiya et al., 2016), e como

resultado, o número de referências n pontos (H) pode ser calculado usando a Eq.

$$(2) \text{ com } H = 190$$

Para o algoritmo metaheurístico MOPSO, 7 parâmetros são calibrados. Semelhante ao ajuste

de parâmetros NSGA, três níveis de valor para cada parâmetro foram obtidos na literatura. Como

resultado, um $n = 27$ (3 n)

O design Taguchi é utilizado para ajustar os parâmetros. Os parâmetros de interesse são: (1)

tamanho da população de partículas (n); (2) número máximo de iterações de pesquisa (M) antes do

algoritmo P terminação; (3)

número de repositório (n_r); (4) μ taxa de ação para cada partícula ($\mu_{avaliar}$); (5) peso de inércia (C);

(6) coeficiente de aprendizagem local (c_l), e (7) global

coeficientes de aprendizagem (c_g) para atualizar a velocidade de μ partículas.

Observe que, apenas o μ valor inicial de C está calibrado enquanto será

de μ inco na te en μ d de cada iteração por:

$$C = C \times d \cdot C_{\text{umido}}, \quad (3)$$

Onde C_{umido} é uma taxa de amortecimento de peso de inércia, (por exemplo, $C_{\text{umido}} = 0,99$).

A principal característica das soluções ótimas de Pareto é que essas soluções são incapazes de

melhorar um dos objetivos sem sacrificar outros objetivos. No entanto, na prática, estamos

interessados em selecionar uma solução do conjunto ótimo de soluções de Pareto, também

chamada de solução coordenada. Encontrar uma solução coordenada se torna mais difícil quando o

$$\mu(F) = \begin{cases} 0 & F_{\text{eu}} \leq F_{\text{eu}}^{\min} \\ \frac{F_{\text{eu}}^{\max} - F_{\text{eu}}}{F_{\text{eu}}^{\max} - F_{\text{eu}}^{\min}} & F_{\text{eu}}^{\min} < F_{\text{eu}} < F_{\text{eu}}^{\max} \\ 1 & F_{\text{eu}} \geq F_{\text{eu}}^{\max} \end{cases} \quad (4)$$

F_{eu}^{\min} e F_{eu}^{\max} indicam as soluções menos e mais satisfatórias para o

μ função objetivo entre a frente de Pareto, respectivamente. O intervalo para

a função de adesão μ está entre 0 e 1, onde $\mu = 0$ denota a incompatibilidade da solução e μ

1 denota compatibilidade total.

As funções de objetivo de confiabilidade e maximização de fluxo são analisadas de forma

equivalente para minimizar o valor negativo para confiabilidade e fluxo. Como resultado, todos os

objetivos correspondem a 'quanto menor, melhor' pelos graus medidos na Eq. (4). A função de

associação normalizada para cada membro de Pareto k é calculado com base em:

$$\mu_k = \frac{\sum_{i=1}^n \mu_i}{\sum_{k=1}^M \sum_{i=1}^n \mu_i}, \quad (5)$$

onde M é o número de membros de Pareto e n é o número de

funções objetivas. A função μ_k pode ser realizado o como a função de pertinência para soluções não

dominadas em um conjunto fuzzy. Nesse caso, o

melhor solução de compromisso é a solução com o máximo de membros, seguindo o processo de

decisão fuzzy fornecido por Zimmermann (2011).

$$\text{Maximize} = \min_{\text{eu}} \dots \min_{k} \{ \mu_k(x) \} \quad (6)$$

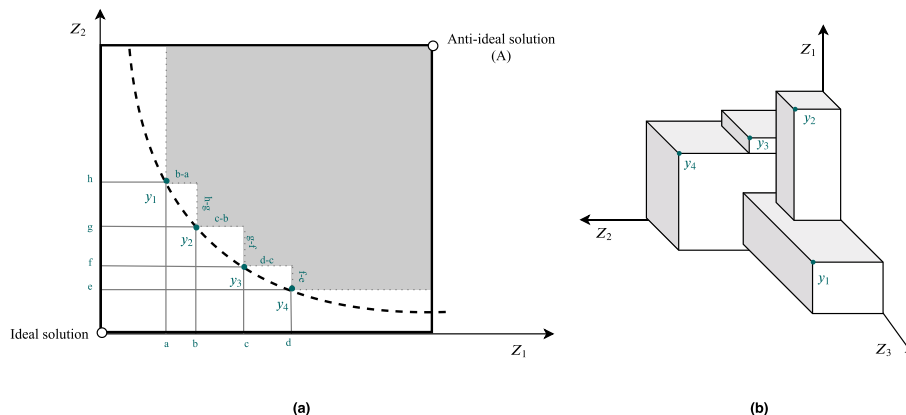


Fig. 3. (a) HV superfície para um problema com duas funções objetivo, (b) HV volume para um problema com funções de três objetivos e várias soluções frontais de Pareto.

Tabela 3

Comparação entre os resultados de diferentes algoritmos metaheurísticos em problemas de pequena e grande escala (P = Problema, N = Nós, R = Confiabilidade, $\text{você}/\text{=}$ Limite superior para fluxos, NOM = Número de membros de Pareto, MID = Distância Média Ideal, = Diversidade, HV_i = Índice de hiper-volume).

Propriedades do cenário										MOPSO com 1000 iterações e $nP=250$					NSGA-II com 200 iterações e $nP=250$					NSGA-III com 500 iterações e $nP=200$				
P	N	R	seed(su)	NOM (média)	MID	Δ	HV _{eu}	Tempo (min)	NOM (média)	MID	Δ	HV _{eu}	Tempo (min)	NOM (média)	MID	Δ	HV _{eu}	Tempo (min)						
S1	6	0.75	[50.600]	203	1.26E+06	1.36E+06	1.13E+08	31.6	249	1.38E+06	2.88E+06	1.89E+08	11.1	200	7.33E+05	3.64E+07	2.81E+08	10.9						
S2	6	0.75	[2k, 6k]	195	3.65E+07	5.62E+07	3.79E+08	31.9	217	5.98E+07	7.94E+06	4.23E+08	12.3	197	1.38E+07	9.06E+06	6.76E+08	9.8						
S3	6	0.85	[50.600]	165	1.34E+06	3.11E+06	9.18E+07	31.1	250	1.43E+06	3.00E+06	8.73E+07	11.8	200	9.59E+05	4.88E+06	9.84E+07	9.7						
S4	6	0.85	[2k, 6k]	172	3.21E+07	6.53E+07	9.88E+07	32.0	188	5.25E+07	7.94E+06	1.85E+08	11.9	196	1.85E+07	9.48E+06	2.53E+08	11.0						
S5	6	0.95	[50.600]	177	1.95E+06	2.44E+06	9.60E+06	31.4	246	2.89E+06	5.02E+06	1.10E+07	11.0	198	1.06E+06	2.85E+07	9.89E+06	10.8						
S6	6	0.95	[2k, 6k]	185	3.68E+07	5.04E+06	2.07E+07	32.5	198	7.23E+07	7.94E+06	1.37E+07	11.8	197	2.25E+07	8.90E+06	4.51E+07	11.2						
S7	10	0.75	[50.600]	176	4.18E+06	7.29E+06	7.55E+08	39.2	246	3.93E+06	8.47E+06	1.27E+09	12.9	176	1.44E+06	7.56E+06	8.84E+08	16.9						
S8	10	0.75	[2k, 6k]	210	4.50E+07	5.08E+07	2.44E+09	39.9	192	5.48E+07	7.22E+07	5.85E+09	14.1	196	2.87E+07	9.12E+07	7.30E+09	17.6						
S9	10	0.85	[50.600]	209	3.71E+06	5.90E+06	2.23E+08	39.0	138	4.63E+06	7.33E+06	3.14E+08	12.2	190	1.97E+06	8.71E+06	5.24E+08	16.8						
S10	10	0.85	[2k, 6k]	235	5.93E+07	3.08E+07	8.10E+08	30.1	236	7.44E+07	3.96E+07	9.18E+08	13.7	197	3.78E+07	6.77E+07	1.06E+09	17.7						
S11	10	0.95	[50.600]	241	5.01E+06	5.34E+06	5.19E+07	38.9	210	6.30E+06	4.94E+06	3.54E+07	12.6	194	2.37E+06	6.88E+06	6.68E+07	17.0						
S12	10	0.95	[2k, 6k]	226	6.23E+07	7.75E+07	4.88E+08	39.8	203	8.19E+07	8.25E+07	3.00E+08	13.9	199	4.13E+07	1.15E+08	7.11E+08	17.1						
Média				199.5	2.41E+07	2.59E+07	4.57E+07	34.78	195.58	3.47E+07	2.08E+07	8.00E+08	12.44	195	1.43E+07	3.29E+07	1.5E+09	13.83						
L1	30	0.75	[100.800]	223	6.75E+06	8.91E+06	2.61E+07	120.8	234	3.73E+06	5.86E+07	6.93E+07	32.4	196	1.08E+06	4.73E+07	3.31E+08	55.3						
L2	30	0.75	[3k, 7k]	217	7.67E+07	3.24E+06	8.90E+07	122.2	223	6.66E+07	3.13E+07	3.21E+08	34.1	193	2.16E+07	5.18E+06	4.15E+08	57.2						
L3	30	0.85	[100.800]	197	7.08E+06	1.02E+06	1.78E+07	120.5	217	4.47E+06	6.44E+05	2.77E+07	31.9	197	1.14E+06	8.31E+05	3.60E+07	56.1						
L4	30	0.85	[3k, 7k]	242	7.83E+07	2.35E+07	2.25E+08	122.0	250	6.93E+07	7.51E+06	8.58E+07	34.3	200	2.23E+07	9.09E+06	5.35E+08	58.4						
L5	30	0.95	[100.800]	203	6.54E+06	6.59E+07	6.64E+08	119.9	222	4.32E+06	8.43E+08	9.72E+08	30.8	200	1.18E+06	7.34E+08	2.19E+09	55.8						
L6	30	0.95	[3k, 7k]	227	6.63E+07	4.70E+06	1.11E+08	121.8	236	5.88E+07	7.29E+06	6.34E+07	34.5	182	2.72E+07	6.93E+06	5.08E+08	57.9						
L7	40	0.75	[100.800]	187	7.68E+06	9.87E+05	8.87E+07	133.7	196	8.40E+06	8.04E+06	2.08E+08	49.0	200	2.22E+06	1.65E+07	4.91E+08	66.3						
L8	40	0.75	[3k, 7k]	175	7.89E+07	2.46E+07	3.22E+08	135.4	188	5.12E+07	2.76E+07	5.85E+08	50.6	194	4.48E+07	4.80E+07	3.62E+09	72.3						
L9	40	0.85	[100.800]	218	7.94E+06	2.89E+06	3.74E+07	134.3	223	6.05E+06	8.68E+05	4.12E+07	47.8	200	2.27E+06	9.77E+05	7.24E+07	69.7						
L10	40	0.85	[3k, 7k]	176	8.27E+07	6.77E+06	5.71E+08	137.7	197	8.14E+07	7.66E+06	8.39E+08	50.3	189	5.33E+07	1.18E+07	3.41E+09	72.0						
L11	40	0.95	[100.800]	215	7.71E+06	8.69E+07	9.79E+08	133.4	217	4.79E+06	5.37E+08	2.76E+09	49.2	190	2.51E+06	2.08E+08	4.68E+09	71.3						
L12	40	0.95	[3k, 7k]	199	10.9E+07	9.57E+08	6.19E+08	135.0	195	8.5E+07	8.40E+07	7.95E+08	49.9	191	6.09E+07	3.21E+09	1.88E+09	71.7						
Média				206.5	4.46E+07	9.89E+07	3.12E+08	128.05	236.32	3.7E+07	1.34E+08	5.64E+08	41.23	194.2	2.0E+07	3.58E+08	1.51E+09	63.83						
média geral				203	3.4E+07	6.2E+07	3.8E+08	81.4	215.8	3.6E+07	7.8E+07	6.8E+08	26.84	194.6	1.7E+07	2.0E+08	1.3E+09	38.85						

sujeito às mesmas restrições do problema original, onde k denota o número de funções objetivo e

ω_{eu} é o fator de peso não.

($0 \leq \omega_{eu} \leq 1$) correspondendo a cada objetivo f_u

4.5. Critérios de comparação para soluções ótimas de Pareto

Entre várias métricas de desempenho comumente usadas para problemas multi-objetivos (Tavana, Li, Mobin, Komaki e Teymourian, 2016), cinco métricas altamente relacionadas são usadas para avaliar a taxa de convergência e a diversidade de soluções ótimas de Pareto para cada um dos algoritmos: (1) número médio de membros de Pareto (NOM), (2) Diversidade (Δ) (Zitzler, 1999), (3) distância ideal média (MID) (Karimi, Zandieh e Karamooz, 2010), (4) indicador de hiper-volume (HV_{EU}) e (5) tempo de CPU para alcançar as soluções finais.

Número médio de membros Pareto (NOM) mostra a capacidade de um algoritmo de fornecer diversas soluções comprometidas. Observe que o número de membros de Pareto não pode exceder o tamanho da população (n_p) de um algoritmo.

$$\Delta = \frac{1}{n} \sqrt{\sum_{i=1}^n \max_{j=1, \dots, n} \{f_j(x_i) - f_j(x_{best})\}^2} \quad (7)$$

onde na Eq. (7), n representa o número de funções objetivo e n representa o número de soluções de Pareto. demonstrar a diferença entre todas as soluções ótimas entre a melhor e a pior solução para cada função objetivo de Pareto.

Outra métrica para comparar a diversidade de solução é chamada MID e é formulado da seguinte forma:

$$MID = \frac{1}{n} \sum_{i=1}^n \frac{d_i}{\max_j \{f_j(x_{best})\}} \quad (8)$$

Da mesma forma, na Eq. (8), n está representando o número de soluções de Pareto e d_i é a distância euclidiana de eu_i Solução de Pareto do ponto ideal para cada função objetivo. O ponto ideal para maximizar o primeiro objetivo, conforme mostrado na Eq. (1a) é $\{1\}$, descrevendo uma rede totalmente confiável. O ponto ideal para minimizar custos, conforme mostrado na Eq. (1c), pode ser considerado $\{0\}$, embora irrealista. No entanto, para maximizar o fluxo, a Eq. (1b), uma solução ideal não está disponível intuitivamente e $\{\max(z_3)\}$ é usado para os cálculos.

Hipervolume (HV), também conhecido como S métrica, é uma medida para quantificar a quantidade de espaço objetivo que está sendo dominado pela frente de Pareto obtida. HV tem sido uma métrica de desempenho preferida na literatura multi-objetivo, uma vez que captura tanto a distância relativa das soluções para o conjunto ótimo quanto a propagação das soluções através do espaço objetivo usando um único escalar (Enquanto, Hingston, Barone, & Huband, 2006)

Considerando um ponto de referência (A) como o anti-ideal ou a pior solução dentro do espaço da função objetivo, o volume que é delimitado por um ponto anti-ideal e um ponto ótimo de Pareto forma o hipervolume. Uma limitação da métrica HV é que os valores da função objetivo devem ser normalizados antes de determinar o hiper-volume (Ciro, Dugardin, Yalaoui e Kelly, 2016)

No Fig. 3 a, o cálculo para hiper-volume de um problema com dois funções objetivo de minimização é uma superfície fornecida pela agregação dos retângulos criados pelo ponto de referência (A) e a frente de Pareto solução (neste exemplo, y_1, y_2, y_3 , e y_4). Em um problema de três objetivos, a realização do hipervolume cria um volume, conforme mostrado em Fig. 3 b.

A fim de calcular o indicador de hipervolume, denotado como HV_{EU} , para um conjunto de solução ideal de Pareto X , delimitado por um ponto de referência $A = (a_1, \dots, a_k) \in \mathbb{R}^k$ a seguinte formulação pode ser utilizada:

$$HV_{EU}(X) = \int_{a \in A} \prod_{k=1}^k [f_k(x) - a_k] \times \lambda(x) \quad (9)$$

Onde, $\lambda(x)$ é a Medida Lebesgue de um conjunto S e $[f_k(x) - a_k]$ é o k -hipercuboide dimensional que consiste em todos os pontos não dominados em relação ao ponto de referência. Nos últimos anos, os métodos exatos e aproximados são usados para calcular HV_{EU} (Jaszkiewicz, 2018; Oliveira, Wanner, de Souza, Bezerra, & Stützle, 2019; Zitzler, Brockhoff e Thiele, 2007) Nesta pesquisa, o hipervolume é aproximado usando o método de Monte-Carlo (MC), conforme proposto por Krusselbrink (2015).

5. Resultados e comparação de desempenho de métodos de solução

Conforme elaborado anteriormente com detalhes, o problema de otimização multiobjetivo (apresentado na Eq. (1)) foi resolvido por três algoritmos metateurísticos, nomeadamente NSGA-II, NSGA-III e MOPSO e os resultados são comparados. Todos os algoritmos são implementados em MATLAB R2010a e resolvidos em um processador Core 2 Duo / 2,66 GHz e 2 GB de memória RAM. Doze instâncias numéricas para a pequena escala e doze instâncias numéricas para a grande escala são geradas aleatoriamente para comparar o desempenho desses algoritmos. A escala das instâncias é definida em função das variáveis de decisão e das restrições.

Com um aumento no tamanho (da rede, número de nós (n), e número de arcos associados $2 \times (n$

2) também aumentam. Estudos anteriores sugerem que um problema pode ser referido em grande escala, uma vez que o tamanho de o problema ultrapassa 1000 (Benson, Shanno e Vanderbei, 2003) Consequentemente, o incremento no número de variáveis de decisão e restrições tornam o problema intratável e fornecem bons candidatos para comparar os métodos de solução para instâncias mais realistas.

As instâncias numéricas são introduzidas em Tabela 3, onde o número de nós (N), a confiabilidade do arco (R), e limite superior do fluxo ($VOC_{EU,j}$) variam entre as instâncias. O número de nós para problemas de pequena e grande escala são definidos como (6 e 10) e (30 e 40), respectivamente.

Confiabilidade do arco ($R \in \{0,75, 0,85, 0,95\}$) é definido como o inverso de probabilidade de falha de arcos ($1 - q$). Fator de transmissão correspondente ($uma_{eu,j}$) para cada arco é gerado aleatoriamente na forma de $N \times N$ matrizes em um intervalo aceitável. Para todos (n

fluxo limitado de arco eu_j , ($VOC_{EU,j}$, uma 2) a geração aleatória com distribuição uniforme distribuição. Em problemas de pequena escala, a variável aleatória é escolhida de tal modo que $voc_{ij} - VOC_{\hat{ij}} (50, 600)$ e $voc_{ij} - VOC_{\hat{ij}} (2000, 6000)$. Da mesma forma, o limite superior para problemas de grande escala são gerados aleatoriamente pelo uniforme distribuições com o intervalo tal que $voc_{ij} - VOC_{\hat{ij}} (100, 800)$ e $voc_{ij} - VOC_{\hat{ij}} (3000, 7000)$. Desde o custo do fluxo ($CF_{eu,j}$) depende diretamente do

Tabela 4

Comparação estatística de métricas de desempenho usando o teste de Kruskal-Wallis com ($\alpha = 0,05$).

Performance Metrics	Teste Kruskal-Wallis			
	Instâncias de pequena escala		Instâncias em grande escala	
	P-Value	Resultados	P-Value	Resultados
Razão NOM	0,004	NSGA-III é preferido	0,000	NSGA-III é preferido
Proporção de diversidade (Δ)	0,073	Não há diferença significativa NSGA-III e	0,054	Não há diferença significativa NSGA-III e
proporção MID	0,049	MOPSO são preferidos Não há diferença	0,040	MOPSO são preferidos NSGA-II e NSGA-III
HV_{eu} Razão	0,061	significativa NSGA-III e MOPSO são	0,003	são preferidos NSGA-III e MOPSO são
Proporção de tempo de CPU	0,000	preferidos	0,000	preferidos

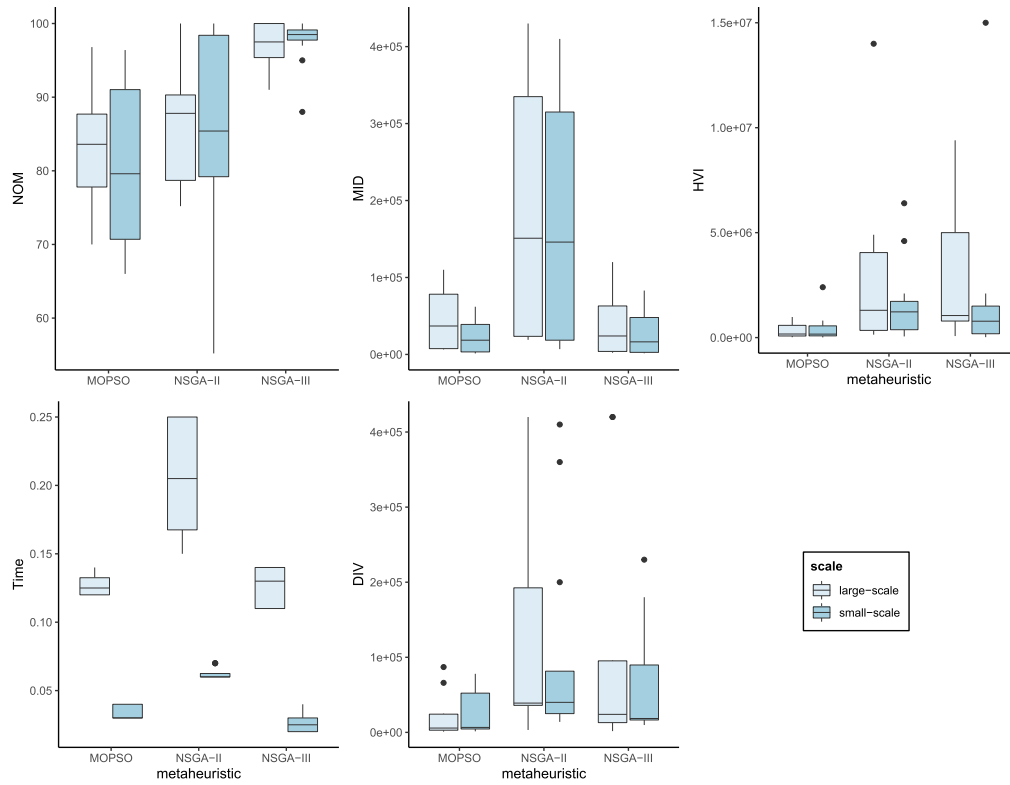


Fig. 4. Análise estatística de métricas de comparação de desempenho usando Box Plot.




(a) MOPSO results for 2nd, 500th and 1000th iterations.(b) NSGA-II results for 2nd, 100th and 200th iterations.(c) NSGA-III results for 2nd, 250th and 500th iterations.

Fig. 5. Todas as soluções, membros frontais de Pareto e a melhor solução de compromisso na primeira, no meio e nas iterações finais da instância do problema S3 por (a) MOPSO, (b) NSGA-II e (c) NSGA-III.

quantidade de fluxo ($f_{eu,j}$), o custo por unidade de fluxo através dos arcos e custo de construir arcos ($CB_{eu,j}$) são definidos como uma fração aleatória de $VOC_{eu,j}$ em um intervalo pré-definido.

Cada instância é resolvida por todos os métodos metaheurísticos com os valores dos parâmetros calibrados conforme mostrado anteriormente na Seção 4.3.1. Correspondentemente, todas as métricas de desempenho, relatadas na Seção 4.5, são calculados. Como mostrado em Tabela 3, as métricas de desempenho fornecem uma plataforma precisa para comparar a eficiência e a diversidade de soluções candidatas fornecidas pelos algoritmos de solução.

Como mostrado em Tabela 3, as escalas de instâncias têm impacto significativo no tempo de CPU e índice de hipervolume (HV_{EU}). Por exemplo, o tempo necessário para executar o algoritmo, ou o tempo de CPU, varia de 12,44 a

34,78 min para instâncias de pequena escala, enquanto que para instâncias de grande escala o intervalo é escalado para ser entre 41,23 e 128,05 min. A métrica de desempenho MID demonstrou ser mais robusta em termos da escala das instâncias onde o valor não mudou significativamente uma vez que o tamanho de

os problemas aumentaram. os valores para NOM médio, diversidade (Δ), HV_{EU} , e o tempo de CPU para NSGA-II, NSGA-III e MOPSO variam com base no tamanho e propriedade das instâncias. Comparando o desempenho geral das três metaheurísticas, a porcentagem de NOM ou proporção do número de

Membros de Pareto em comparação com o tamanho da população (n_p) é 82,6%, 86,6% e 97,3% para MOPSO, NSGA-II e NSGA-III, respectivamente. A tendência é consistente para ambos os problemas de pequena escala.

Para comparar o desempenho dos três métodos estatisticamente, é utilizado o teste de Kruskal-Wallis, que é um teste não paramétrico para determinar se a mediana de dois ou mais grupos de variáveis independentes são estatisticamente significativamente diferentes. O teste de Kruskal-Wallis pode classificar os dados da amostra de forma eficiente e mostrar se as amostras são originadas da mesma distribuição.

Uma vez que o valor de algumas das métricas de desempenho são dependentes das propriedades do método metaheurístico que são calibradas individualmente (por exemplo, iterações metaheurísticas numéricas (M_{isto}) e tamanho da população (n_p)), os resultados são normalizados antes de realizar o teste de Kruskal-Wallis. O os valores normalizados das métricas de desempenho resultam em uma comparação justa e imparcial entre os três algoritmos metaheurísticos. Os resultados do teste de Kruskal-Wallis para cada métrica de desempenho são apresentados em Tabela 4. Os resultados do teste indicam que o NSGA-III é mais favorável em comparação com o NSGA-II e o MOPSO no ponto de vista de fornecer membros de Pareto mais elevados (NOM). NSGA-III e MOPSO compartilham o melhor desempenho em relação à taxa de tempo de CPU e análise de proporção MID. No entanto, NSGA-II e NSGA-III superam MOPSO em termos de obtenção de maior

hiper-volume para problemas de grande escala. Não há diferença significativa na distribuição de soluções para o desempenho da Diversidade (Δ) métrica e HV_{EU} em instâncias de pequena escala.

Finalmente, as propriedades das métricas de desempenho são comparadas por meio de box-plots para mostrar o desvio de 1st quartil, mediana e 3rd quartil dos resultados. Fig. 4 representa os box-plots para instâncias de pequena e grande escala, enquanto para DIV, alguns dos outliers são truncados para fins de melhor dimensionamento. Como esperado, quando o tamanho do problema aumenta, o tempo de CPU também aumenta. Além disso, há uma relação direta entre o tamanho do problema e o hipervolume que as abordagens NSGA podem atingir. Olhando para o número de membros ideais de Pareto (NOM), O NSGA-III supera o NSGA-II e o MOPSO, não apenas pelo valor da mediana, mas também pelo menor desvio entre todas as instâncias. Os resultados para MID é diferente onde NSGA-III e MOPSO fornecem melhores soluções. em geral, o NSGA-III é a abordagem de solução preferida para problemas de pequena e grande escala.

A fim de visualizar a progressão dos algoritmos e sua força em encontrar membros da frente de Pareto de alta qualidade, as soluções de primeira, meio e iteração final de cada método metaheurístico para a instância do problema S3 é ilustrado em Fig. 5. Nessas figuras, além dos membros da frente de Pareto e a melhor solução comprometida correspondente, *Camada interna* e *Camada limite* são demonstrados. *Camada interna* é uma superfície composta de pontos de referência que se cruzam com os melhores valores da função objetivo, retirados do ponto ideal, (Z_{min}) nos eixos de coordenadas 3D, e *camada limite* é uma superfície com eu posta de pontos de referência que cruzam com os piores valores da função objetivo (Z_{max}) (Deb & Jain, 2014). Os números demonstram que nas primeiras iterações, o número e a diversidade de soluções ótimas de Pareto são limitados. Conforme o número de iterações aumenta, mais soluções ótimas de Pareto são alcançadas, cobrindo um espaço de solução maior. Observe que, embora a iteração MOPSO tenha sido definida como 1000, o número de soluções ótimas de Pareto é menor em comparação com NSGA-II e NSGA-III.

Outra implicação de Fig. 5 é a qualidade das soluções fornecidas pelo NSGA-II, NSGA-III e MOPSO em diferentes iterações. Conforme as iterações avançam, a distância entre as soluções e o *camada limite* aumentar. Ao mesmo tempo, as soluções de frente de Pareto tornam-se mais próximas de *camada interna*, como uma indicação de resultados de qualidade superior.

Para o propósito de comparar a qualidade dos membros de Pareto computados pelas três metaheurísticas em uma plataforma, Fig. 6 ilustra uma comparação de pares de funções objetivo para uma pequena escala (S3) e um em grande escala (L4) problemas. Em geral, os membros NSGA-III Pareto são

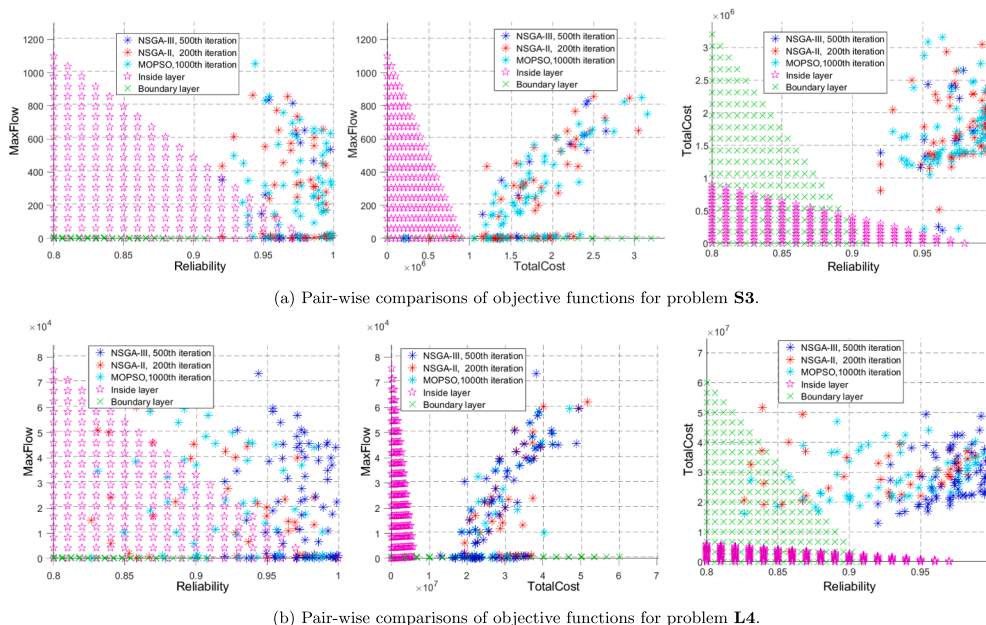


Fig. 6. Comparação de pares de membros da frente de Pareto na iteração final de diferentes algoritmos para (a) instância de pequena escala S3, e (b) instância em grande escala L4.

Tabela 5
Melhor solução de compromisso de exemplos de instâncias de cada algoritmo metaheurístico. (%) indica a razão de diferença entre a solução fornecida e a melhor solução entre os diferentes métodos (+). (P = problema, N = nós, R = confiabilidade).

Propriedades do cenário				MOPSO			NSGA-II			NSGA-III		
P	N	R	velocidade	Confiabilidade	Custo	Fluxo	Confiabilidade	Custo	Fluxo	Confiabilidade	Custo	Fluxo
S1	6	0.75	[50.600]	0.88 (-4%)	3.20E + 06 (+)	9.80E + 02 (+)	0.92 (+)	2.20E + 06 (-31%)	6.30E + 02 (-36%)	0.9 (-2%)	2.40E + 06 (-25%)	8.10E + 02 (-17%)
S2	6	0.75	[2k, 6k]	0.9 (-1%)	8.80E + 06 (+)	1.40E + 04 (+)	0.91 (+)	8.30E + 06 (-6%)	1.30E + 04 (-7%)	0.9 (-1%)	8.80E + 06 (+)	1.40E + 04 (+)
S3	6	0.85	[50.600]	0.93 (-2%)	3.00E + 06 (+)	9.40E + 02 (+)	0.95 (+)	2.30E + 06 (-23%)	6.50E + 02 (-31%)	0.93 (-2%)	3.00E + 06 (+)	9.40E + 02 (+)
S4	6	0.85	[2k, 6k]	0.91 (-5%)	8.90E + 06 (-4%)	1.40E + 04 (-7%)	0.96 (+)	9.00E + 06 (-3%)	1.40E + 04 (-7%)	0.94 (-2%)	9.30E + 06 (+)	1.50E + 04 (+)
S5	6	0.95	[50.600]	0.95 (-3%)	2.40E + 06 (-17%)	7.80E + 02 (-12%)	0.98 (+)	2.80E + 06 (-3%)	8.50E + 02 (-4%)	0.97 (-1%)	2.90E + 06 (+)	8.90E + 02 (+)
S6	6	0.95	[2k, 6k]	0.95 (-2%)	9.30E + 06 (-2%)	1.50E + 04 (+)	0.98 (-1%)	8.70E + 06 (-8%)	1.20E + 04 (-20%)	0.97 (+)	9.50E + 06 (+)	1.50E + 04 (+)
S7	10	0.75	[50.600]	0.87 (-3%)	5.20E + 06 (-2%)	2.30E + 03 (-4%)	0.89 (-1%)	5.20E + 06 (-2%)	2.30E + 03 (-4%)	0.9 (+)	5.30E + 06 (+)	2.40E + 03 (+)
S8	10	0.75	[2k, 6k]	0.89 (+)	1.40E + 07 (-7%)	5.20E + 04 (-17%)	0.86 (-3%)	1.20E + 07 (-20%)	4.90E + 04 (-22%)	0.86 (-3%)	1.50E + 07 (+)	6.30E + 04 (+)
S9	10	0.85	[50.600]	0.93 (-3%)	6.70E + 06 (-1%)	2.10E + 03 (-5%)	0.92 (-4%)	6.80E + 06 (+)	2.20E + 03 (+)	0.96 (+)	6.70E + 06 (-1%)	2.10E + 03 (-5%)
S10	10	0.85	[2k, 6k]	0.91 (+)	1.50E + 07 (-25%)	6.10E + 04 (-27%)	0.9 (-1%)	2.00E + 07 (+)	7.30E + 04 (-13%)	0.91 (+)	1.90E + 07 (-5%)	8.40E + 04 (+)
S11	10	0.95	[50.600]	0.98 (+)	8.10E + 06 (-1%)	2.50E + 03 (-4%)	0.97 (-1%)	4.70E + 06 (-43%)	1.70E + 03 (-35%)	0.98 (+)	8.20E + 06 (+)	2.60E + 03 (+)
S12	10	0.95	[2k, 6k]	0.97 (-1%)	1.60E + 07 (-27%)	5.90E + 04 (-23%)	0.98 (+)	1.80E + 07 (-18%)	6.50E + 04 (-16%)	0.98 (+)	2.20E + 07 (+)	7.70E + 04 (+)
L1	30	0.75	[100.800]	0.84 (-7%)	5.70E + 07 (-7%)	9.30E + 04 (-7%)	0.88 (-2%)	5.80E + 07 (-8%)	9.10E + 04 (-9%)	0.9 (-)	6.10E + 07 (+)	1.00E + 05 (+)
L2	30	0.75	[3k, 7k]	0.84 (-1%)	9.30E + 07 (-1%)	2.70E + 06 (-7%)	0.85 (+)	9.30E + 07 (-1%)	2.70E + 06 (-7%)	0.85 (+)	9.40E + 07 (+)	2.80E + 06 (+)
L3	30	0.85	[100.800]	0.92 (-3%)	5.10E + 07 (-18%)	8.80E + 04 (-20%)	0.94 (-1%)	5.20E + 07 (-16%)	8.90E + 04 (-19%)	0.95 (+)	6.20E + 07 (+)	1.10E + 05 (+)
L4	30	0.85	[3k, 7k]	0.88 (-3%)	9.40E + 07 (+)	2.80E + 06 (+)	0.91 (+)	8.90E + 07 (-5%)	2.60E + 06 (-7%)	0.89 (-2%)	9.30E + 07 (-1%)	2.80E + 06 (+)
L5	30	0.95	[100.800]	0.97 (-1%)	6.30E + 07 (+)	9.70E + 04 (-12%)	0.98 (+)	5.70E + 07 (-10%)	9.20E + 04 (-16%)	0.96 (-2%)	6.20E + 07 (-2%)	1.10E + 05 (+)
L6	30	0.95	[3k, 7k]	0.93 (-1%)	9.50E + 07 (-1%)	2.90E + 06 (-6%)	0.94 (+)	9.40E + 07 (-2%)	2.80E + 06 (-10%)	0.92 (-2%)	9.60E + 07 (+)	3.10E + 06 (+)
L7	40	0.75	[100.800]	0.89 (-1%)	7.60E + 07 (+)	1.70E + 05 (-11%)	0.9 (+)	7.40E + 07 (-3%)	1.90E + 05 (+)	0.9 (+)	7.50E + 07 (-1%)	1.90E + 05 (+)
L8	40	0.75	[3k, 7k]	0.87 (-3%)	3.40E + 08 (+)	4.00E + 06 (-9%)	0.9 (+)	3.30E + 08 (-3%)	4.10E + 06 (-7%)	0.86 (-4%)	3.40E + 08 (+)	4.40E + 06 (+)
L9	40	0.85	[100.800]	0.92 (+)	7.80E + 07 (+)	2.20E + 05 (+)	0.91 (-1%)	7.70E + 07 (-1%)	1.70E + 05 (-23%)	0.92 (+)	7.80E + 07 (+)	2.20E + 05 (+)
L10	40	0.85	[3k, 7k]	0.93 (+)	3.10E + 08 (-3%)	4.20E + 06 (+)	0.93 (+)	3.20E + 08 (+)	3.90E + 06 (-2%)	0.93 (+)	3.10E + 08 (-3%)	4.10E + 06 (-2%)
L11	40	0.95	[100.800]	0.96 (-2%)	7.50E + 07 (-4%)	1.80E + 05 (-10%)	0.98 (+)	7.80E + 07 (+)	1.90E + 05 (-5%)	0.98 (+)	7.60E + 07 (-3%)	2.90E + 05 (+)
L12	40	0.95	[3k, 7k]	0.96 (-1%)	3.00E + 08 (-9%)	4.20E + 06 (-5%)	0.97 (+)	3.10E + 08 (-6%)	4.00E + 06 (-9%)	0.96 (-1%)	3.30E + 08 (+)	4.40E + 06 (+)

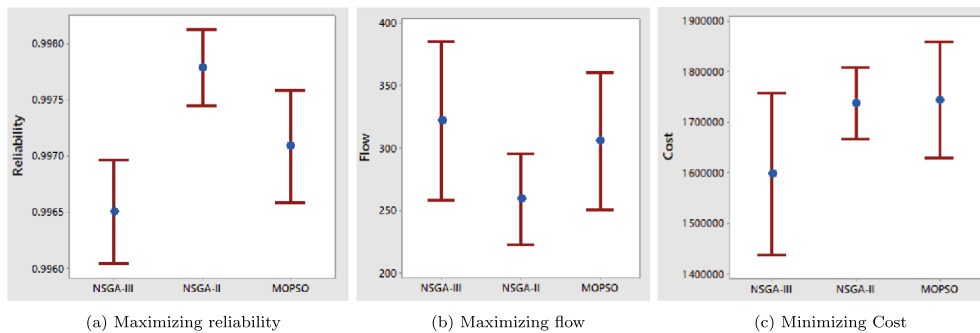


Fig. 7. Comparação entre intervalo de confiança de 95% para a média de cada função objetivo.

mais perto da interseção de pontos ideais ou *camada interna*. Por exemplo, subfiguração certa de Fig. 6 b representa a comparação entre confiabilidade e custo, onde NSGA-III fornece soluções de maior confiabilidade com menor custo, em comparação com NSGA-II e MOPSO. Da mesma forma, quando a confiabilidade é comparada, como mostrado na subfigura esquerda de Fig. 6 b, NSGA-III supera NSGA-II e MOPSO. Observe que uma tendência consistente nos resultados foi observada para problemas de pequena e grande escala.

Além de comparar a avaliação de desempenho entre os métodos meta-heurísticos, a melhor solução de compromisso de cada instância da amostra, correspondente a cada função objetivo, é mostrada em Tabela 5. Nesta tabela, os números em negrito representam a melhor solução comprometida para cada função objetivo entre os três métodos metaheurísticos. Para uma análise de comparação mais robusta, a diferença percentual para cada função objetivo da melhor função objetivo é calculada e exibida. Enquanto a solução final comprometida de MOPSO, NSGA-II e NSGA-III difere em vários casos, há alguns casos em que as soluções de um algoritmo metaheurístico são completamente dominadas por outro algoritmo. Mais especificamente, para várias instâncias de grande escala, a MOPSO é incapaz de fornecer soluções que não sejam completamente dominadas pelo NSGA-II e NSGA-III.

NSGA-III provou ser robustamente melhor ou igualmente bom, em aproximadamente 34% dos casos, em comparação com MOPSO e NSGA-II em casos de pequena e grande escala. A maioria da superioridade do NSGA-III deve-se ao fornecimento de maior fluxo para a rede, em mais de 87% dos casos, em comparação com os demais algoritmos. O número de casos em que o NSGA-III está superando o NSGA-II e / ou MOPSO em termos de minimização de custo e maximização de confiabilidade das funções objetivas é de 66% e 54%, respectivamente.

Finalmente, os intervalos de confiança de 95% para o valor médio de cada função objetivo são mostrados em Fig. 7. Esta análise fornece a oportunidade de comparar o intervalo de confiança das soluções de frente de Pareto fornecidas por cada método metaheurístico. As soluções frontais Pareto do NSGA-II oferecem maior confiabilidade, em comparação ao MOPSO e ao NSGA-III. Porém, em termos de custo e fluxo, as soluções frontais NSGA-III Pareto oferecem soluções mais robustas. Observe que os desvios padrão individuais são usados para calcular os intervalos.

6. Discussão

Nesta seção, primeiro fornecemos uma visão breve, porém holística, das lacunas específicas cobertas por esta pesquisa e das áreas que ainda precisam ser investigadas. Em seguida, descrevemos os desafios associados aos métodos de solução e elaboramos sua complexidade computacional.

6.1. Pontos fortes e limitações do modelo proposto

Aumentar a confiabilidade das redes é um dos elementos mais fundamentais de muitas redes físicas e virtuais, como com fio, sem fio, cadeia de suprimentos e redes sociais. No entanto, a confiabilidade da rede tem um preço. Esta pesquisa examinou dois objetivos adicionais de minimizar o custo total e maximizar o fluxo, ao projetar

redes confiáveis. Nosso modelo linear inteiro misto proposto busca encontrar a melhor topologia e design de uma rede de forma que os três objetivos conflitantes sejam abordados. A praticidade do modelo depende de levar em consideração características importantes do projeto da rede, como o custo de construção de novos arcos e o custo do fluxo e as taxas de transmissão nas bordas em vez dos nós.

Nossa pesquisa, assim como outras pesquisas, encontra várias limitações que podem ser exploradas posteriormente pelos leitores interessados. Primeiro, as suposições no modelo matemático proposto podem ser revisadas com base nas características de problemas futuros. Por exemplo, a confiabilidade de todos os arcos é considerada semelhante. No entanto, essa suposição limita o uso do modelo para redes complexas. Além disso, em algumas redes, a falha do arco aumenta, pois os arcos adjacentes não funcionam. A contingência entre a falha dos arcos é vista principalmente em eventos extremos perturbadores, como terremotos e furacões. Levando a incerteza em consideração, o modelo pode ser expandido ainda mais com a probabilidade estocástica de falha do arco e o custo do reparo. A exploração adicional pode consistir na adição de fluxos de múltiplos períodos e commodities representando redes mais avançadas.

6.2. Pontos fortes e limitações dos métodos propostos

O modelo matemático proposto é resolvido primeiro com CPLEX para uma instância muito pequena e a solução ótima é verificada para garantir a precisão do modelo. No entanto, para problemas de grande escala, o CPLEX é incapaz de resolver o problema ou atingir uma lacuna de otimização aceitável em um período de tempo razoável. Assim, três métodos metaheurísticos (ie MOPSO, NSGA-II e NSGA-III) são empregados e comparados para resolver o problema proposto.

Várias vantagens e desvantagens estão associadas a cada um desses métodos. A maior vantagem do MOPSO, em comparação com NSGA-II e NSGA-III, é a simplicidade de seu conceito, facilidade de implementação e boa taxa de convergência (Coello, Lamont e Van Veldhuizen, 2007). No entanto, MOPSO não é capaz de controlar a diversidade, em comparação com os outros dois algoritmos metaheurísticos. O NSGA-II é criticado principalmente por suas capacidades exploratórias e vieses de busca quando o número de funções objetivo aumenta. Nesse interim, a força do algoritmo é se espalhar adequadamente quando uma certa região não dominada é encontrada, fornecendo diversas soluções (Coello & Pulido, 2001). De modo geral, o NSGA-III tem mostrado grande superioridade, em comparação ao MOPSO e ao NSGA-II, no fornecimento de maior número de soluções frontais de Pareto e não dominadas com diversidade e convergência razoáveis.

Embora os métodos metaheurísticos sejam altamente utilizados para resolver problemas de grande escala, uma de suas limitações é a complexidade computacional associada. Em geral, a complexidade dos algoritmos evolutivos multiobjetivos é uma função do número de funções objetivo e da terceira potência do tamanho da população, mas pode variar com base no algoritmo de classificação e nas regras de dominação. Especificamente, a complexidade computacional de

MOPSO e NSGA-II em cada iteração é $O(n \times n^2)$ Onde n é o número de funções objetivo e n_p é o tamanho da população (Tripathi, Bandyopadhyay e Pal, 2007). Para NSGA-III, o pior caso geral

complexidade é $O(n^2)$.

Jain, 2013) Enquanto p registro n com p ou putati. O tamanho da população da metaheurística métodos são a favor de menor n_p , o método de solução pode não encontrar soluções quase ótimas, uma vez que o tamanho da população não é suficiente.

Portanto, é importante encontrar o melhor tamanho da população para equilibrar a complexidade computacional e a qualidade das soluções. Isso, por sua vez, introduz outra limitação da solução proposta, que é computacionalmente dispendiosa no ajuste de parâmetros desses métodos. Apesar de existirem várias orientações sobre a melhor faixa de parâmetros a serem usados pelo NSGA-II, NSGA-III e MOPSO, esses parâmetros precisam ser calibrados para cada problema específico. O procedimento de ajuste requer esforço adicional de investigação, o que às vezes é negligenciado em outros estudos de pesquisa. Como resultado do processo de calibração, uma constatação é a capacidade do NSGA-III de fornecer solução de maior qualidade com menor complexidade computacional. Nesta pesquisa, o nível populacional para NSGA-III é 200, em comparação com 250 para MOPSO e NSGA-II.

7. Conclusão

As redes de fluxo desempenham um papel vital em muitas indústrias. Além disso, a segurança e a confiabilidade das redes de fluxo, especialmente redes de infraestrutura, tornaram-se a principal preocupação tanto para gerentes de indústria quanto para formuladores de políticas governamentais. No entanto, a confiabilidade das redes é alcançada com um custo mais elevado, sendo necessário um projeto de modelo que possa comprometer vários objetivos conflitantes de uma rede de fluxo.

Neste artigo, é desenvolvido um modelo matemático linear inteiro misto de três objetivos que otimiza simultaneamente três objetivos de minimizar o custo total, maximizar o fluxo e maximizar a confiabilidade. A minimização do custo compreende o custo da construção dos arcos da rede e o custo do fluxo. Para maximizar o fluxo da rede, um problema de rede de fluxo generalizado com multiplicador positivo para cada arco é considerado para contabilizar a perda de fluxo. A confiabilidade da rede é estimada pelo limite superior de Jan, usado em redes de grande escala onde

calcular a confiabilidade da rede com métodos exatos não é viável. Como a complexidade computacional do modelo proposto é NP-difícil, três métodos metaheurísticos multi-objetivos são usados; Otimização de Enxame de Partículas Multi-objetivo (MOPSO), e dois algoritmos genéticos de classificação não dominados (isto é, NSGA-II e NSGA-III). Cada um dos métodos mostrou capacidades e pontos fortes em fornecer soluções quase ideais para problemas multi-objetivos em grande escala.

Para decidir sobre a seleção da melhor solução de compromisso dos membros da frente de Pareto, um mecanismo baseado em fuzzy é aplicado. Portanto, o modelo proposto leva a um projeto final de rede de fluxo generalizado confiável que representaria o compromisso desejado entre os diferentes objetivos do ponto de vista do tomador de decisão. Para garantir a qualidade dos resultados dos métodos metaheurísticos, a eficiência do MOPSO, NSGA-II e NSGA-III é comparada usando várias métricas de desempenho. Nossos resultados indicam que NSGA-III supera MOPSO e NSGA-II em termos de convergência e tempo de execução para instâncias de pequena e grande escala.

Embora as soluções do NSGA-III sejam promissoras para diferentes casos, nossa análise indica que: (1) a seleção do método para resolver tais problemas complexos de grande escala é importante e (2) métodos híbridos que são cuidadosamente calibrados para os objetivos específicos pode ser benéfico. Por exemplo, MOPSO e NSGA-III têm pontos fortes específicos e um modelo híbrido que pode utilizar os pontos fortes de ambos os métodos e superar as deficiências potenciais de cada método individual pode ser uma direção para pesquisas futuras.

O modelo matemático proposto pode ser estendido de várias maneiras para ser aplicável a redes de infraestrutura com diferentes propriedades. Uma recomendação é a aplicação desses modelos no projeto de redes de computadores sem fio e de energia elétrica. Essas redes podem ter demandas estocásticas que precisam ser atendidas em cada intervalo de tempo. Nesses casos, o modelo pode ser expandido para problemas de fluxo de rede estocásticos, de período múltiplo e de commodities múltiplas.

Apêndice A

O pseudocódigo para calcular a função de penalidade para a função objetivo de confiabilidade considerando as condições totalmente conectadas e de duas conectividade é mostrado em Algoritmo 2.

Algoritmo 2

Consideração das condições totalmente conectadas e de duas conectividade usando a função de penalidade.

1: Calcular V	• Violação de total conectividade
2: Calcular gr UMA C sequência de grau de ph (d)	
3: $V \leftarrow média(d, 2)$	• 2-Violação de conectividade
4: $2dH \leftarrow 1$	• H é o limite superior de Jan
5: para $ou \leftarrow 1$ para V Faz	
6: $m_{ou} \leftarrow \min(d_{ou}, ou - 1)$	• m_{ou} : arestas mínimas conectadas a i
7: $dH \leftarrow q d(i)$	• q : probabilidade de falha
8: Se $m_{ou} \geq 1$ então	
9: $dH \leftarrow dH (* - q d(i) m_i)$	
10: fim se	
11: Se $m_{ou} - 1 \geq m_i + 1$ então	
12: $dH \leftarrow dH (* - q d(i) ou - 1 m_i -$	
13: fim se	
14: $H \leftarrow H - dH$	
15: fim para	
16: Confiabilidade $\leftarrow H$	
17: Violação $\leftarrow V AC + V 2C$	
18: $\beta \leftarrow 5$	
19: $z \leftarrow R - \beta * Violação$	

Referências

Akbaripour, H., & Masehian, E. (2013). Ajuste de parâmetro eficiente e robusto para heur-
algoritmos isticos. *Jornal Internacional de Engenharia e Produção Industrial*

Pesquisa.

Azghandi, R., Griffin, J., & Jalali, MS (2018). Minimização da escassez de drogas em

cadeias de suprimentos farmacêuticos: uma análise baseada em simulação de padrões de recall de medicamentos e políticas de inventário. *Complexidade*, 2018.

Bagherinejad, J., & Dehghani, M. (2016). Otimizando o multidimensional bi-objetivo

- problema de mochila inteira usando otimização de enxame de partículas de classificação não dominada. *Jornal Internacional de Engenharia Industrial e de Sistemas*, 23, 263-289 .
- Beltrán, HF, & Skorin-Kapov, D. (1994). Em falha isolada de custo mínimo imune redes. *Sistemas de telecomunicações*, 3, 183-200 .
- Benson, HY, Shanno, DF, & Vanderbei, RJ (2003). Um estudo comparativo de grandes algoritmos de otimização não linear de escala. *Algoritmos de alto desempenho e software para otimização não linear* (pp. 95-127). Springer .
- Bhesdadiya, RH, Trivedi, IN, Jangir, P., Jangir, N., & Kumar, A. (2016). Um NSGA-III algoritmo para resolução de problema de despacho econômico / ambiental multi-objetivo. *Engenharia Cogent*, 3, 1269383 .
- Cancela, H., Murray, L., & Rubino, G. (2019). Estimativa eficiente de fluxo estocástico confiabilidade da rede. *Transações IEEE sobre confiabilidade* .
- Chen, XG (2017). Um novo método de estimativa de confiabilidade de rede complexa com base em monte carlo. *Cluster Computing*, 20, 1063-1073 .
- Ciro, GC, Dugardin, F., Yalaoui, F., & Kelly, R. (2016). A NSGA-II e NSGA-III com parison para resolver um problema de programação de loja aberta com restrições de recursos. *IFAC- PapersOnLine*, 49, 1272-1277 .
- Coello, CAC, Lamont, GB e Van Veldhuizen, DA (2007). *Algoritmos evolutivos para resolvendo problemas multi-objetivos*, vol. 5, Nova York: Springer79-104 .
- Coello, CA e Pulido, GT (2001). Otimização multiobjetivo usando um micro-gene algoritmo. *Anais da 3ª conferência anual sobre computação genética e evolutiva* (pp. 274-282). Morgan Kaufmann Publishers Inc .
- Coello, CAC, Pulido, GT e Lechuga, MS (2004). Lidando com vários objetivos com otimização de enxame de partículas. *IEEE Transactions on Evolutionary Computation*, 8, 256-279 .
- Cohen, E., & Megiddo, N. (1994). Novos algoritmos para fluxos de rede generalizados. *Programação Matemática*, 64, 325-336 .
- Deb, K., Agrawal, S., Pratap, A., & Meyarivan, T. (2000). Um rápido elitista não dominado algoritmo genético de classificação para otimização multi-objetivo. *Conferência internacional sobre resolução paralela de problemas da natureza* (pp. 849-858). Springer .
- Deb, K., & Jain, H. (2013). Um algoritmo de otimização evolutiva de muitos objetivos usando abordagem de classificação não dominada baseada em ponto de referência, parte i: resolvendo problemas com restrições de caixa. *IEEE Transactions on Evolutionary Computation*, 18, 577-601 .
- Deb, K., & Jain, H. (2014). Um algoritmo de otimização evolutiva de muitos objetivos usando abordagem de classificação não dominada baseada em ponto de referência, parte i: Resolvendo problemas com restrições de caixa. *IEEE Transactions on Evolutionary Computation*, 18, 577-601 .
- Deb, K., Pratap, A., Agarwal, S., & Meyarivan, T. (2002). Um multiobjetivo rápido e elitista algoritmo genético: NSGA-II. *IEEE Transactions on Evolutionary Computation*, 6, 182-197 .
- Deeter, DL, & Smith, AE (1997). Otimização heurística do projeto de rede considerando confiabilidade em todos os terminais. *Simpósio de confiabilidade e sustentabilidade. Procedimentos de 1997, anual* (pp. 194-199). IEEE .
- Dengiz, B., & Smith, AE (2000). Métodos evolutivos para projeto de redes confiáveis. *Otimização de telecomunicações: heurísticas e métodos adaptativos* .
- Dubourg, V., Sudret, B., & Deheeger, F. (2013). Amostragem de importância baseada em metamodelo para análise de confiabilidade estrutural. *Mecânica de Engenharia Probabilística*, 33, 47-57 .
- Ei Khadiri, M., & Yeh, W.-C. (2016). Uma alternativa eficiente para a avaliação exata do problema de confiabilidade de rede de fluxo de caminho mais rápido. *Computadores e Pesquisa Operacional*, 78, 22-32 .
- Elsheikhat, B., Soh, S., Rai, S., & Lazarescu, M. (2015). Projeto de topologia com custo mínimo sujeito à restrição de confiabilidade da rede. *IEEE Transactions on Reliability*, 64, 118-131 .
- Esmailpour, A., Salehi, S., & Safavi, N. (2013). Medidas de diferenciação de qualidade de serviço em redes 4g. *Simpósio de telecomunicações sem fio (WTS) 2013* (pp. 1-5). IEEE .
- Fallah, M., Amir, S., & Yaghini, M. (2014). Uma metodologia de ajuste de parâmetro para mim taheurística baseada no planejamento de experimentos. *Jornal Internacional de Ciências de Engenharia e Tecnologia*, 2, 497-521 .
- Garey, MR (1979). Um guia para a teoria da NP-completude. *Computadores e Intratabilidade* .
- Gertsbakh, IB e Shpungin, Y. (2016). *Modelos de confiabilidade de rede: análise, combinação télicas e Monte Carlo*. CRC Press .
- Guo, J., Li, ZS e Jin, JJ (2018). Avaliação da confiabilidade do sistema com vários níveis formação usando o método de fusão Bayesiano. *Engenharia de confiabilidade e segurança do sistema*, 170, 146-158 .
- Hochbaum, DS (2016). Fluxo de custo mínimo em redes de capacidade unitária e fluxo K de custo convexo são tão fáceis quanto o problema de atribuição com o algoritmo All-Min-Cuts. *pré-impressão arXiv arXiv*: 1610.04012 .
- Jan, R.-H., Hwang, F.-J., & Chen, S.-T. (1993). Otimização topológica de uma comunicação rede de comunicação sujeita a uma restrição de confiabilidade. *Transações IEEE sobre confiabilidade*, 42, 63-70 .
- Jane, C.-C., & Lai, Y.-W. (2017). Avaliação da distribuição e confiabilidade do fluxo máximo em redes dinâmicas de fluxo de múltiplos estados. *European Journal of Operational Research*, 259, 1045-1053 .
- Jaszkiewicz, A. (2018). Algoritmo de hipervolume rápido aprimorado. *Computadores e Operações Pesquisa*, 90, 72-83 .
- Jian, G., Zhaojun, L., & Keyser, T. (2018). Uma abordagem bayesiana para integração multinível anteriores e dados para avaliação da confiabilidade do sistema aeroespacial. *Chinese Journal of Aeronautics*, 31, 41-53 .
- Karimi, N., Zandieh, M., & Karamooz, H. (2010). Programação de grupo bi-objetivo em híbrido flowshop flexível: uma abordagem multifásica. *Sistemas especialistas com aplicativos*, 37, 4024-4032 .
- Kennedy, J., & Eberhart, R. (1995). Otimização de enxame de partículas. *Redes neurais*, 1995. *Proceedings, IEEE International Conference on* (pp. 1942-1948). IEEE .
- Konak, A., Coit, DW, & Smith, AE (2006). Otimização multi-objetivo usando genética algoritmos: um tutorial. *Engenharia de confiabilidade e segurança do sistema*, 91, 992-1007 .
- Konak, A., & Smith, AE (2006). Otimização da confiabilidade da rede. *Manual de otimização em telecomunicações* (pp. 735-760). Springer .
- Konak, A., & Smith, AE (2011). Otimização eficiente de dois nós confiáveis conectados redes: uma abordagem biobjetivo. *INFORMS Journal on Computing*, 23, 430-445 .
- Kruisselbrink, J. (2015). Computação de hipervolume. http://www.sourcecodeonline.com/details/hipervolume_computation.html [conectados; acessado em 19 de julho de 2018].
- Kuipers, FA, Yang, S., Trajanovski, S., & Orda, A. (2014). Fluxo máximo restrito em redes estocásticas. *Protocolos de rede (ICNP)*, 2014 IEEE 22ª conferência internacional sobre (pp. 397-408). IEEE .
- Larsson, C. (2014). *Desenho de redes de comunicação modernas: Métodos e aplicações*. Academic Press .
- Li, Z., Mobin, M., & Keyser, T. (2016). Planejamento de crescimento de confiabilidade multi-objetivo e multi-estágio no estágio inicial de desenvolvimento do produto. *IEEE Transactions on Reliability*, 65, 769-781 .
- Lin, Y.-K. & Chang, P.-C. (2013). Uma nova técnica de avaliação de confiabilidade para estocástico redes de manufatura de fluxo com várias linhas de produção. *IEEE Transactions on Reliability*, 62, 92-104 .
- Lin, Y.-K., & Yeh, C.-T. (2015). Maximização da confiabilidade do sistema para uma rede de computadores encontrando a alocação ótima de duas classes sujeita ao orçamento. *Applied Soft Computing*, 36, 578-588 .
- Malinowski, J. (2016). Análise de confiabilidade de uma rede de fluxo com uma série-paralela-re-estrutura ducível. *IEEE Transactions on Reliability*, 65, 851-859 .
- Mobin, M., Li, Z., & Komaki, G. (2017). Uma abordagem multiobjetivo para a relação em vários estágios planejamento do crescimento da capacidade, considerando o momento de introdução de novas tecnologias. *IEEE Transactions on Reliability*, 66, 97-110 .
- Mousavi, S., Taghiabadi, MMR e Ayanzadeh, R. (2019). Uma pesquisa sobre compressão detecção: resultados clássicos e avanços recentes. *pré-impressão arXiv arXiv*: 1908.01014 .
- Namin, AT, Kamarthi, S., Eckelman, MJ e Isaacs, JA (2019). Comparação de nós locais de fabricação de pvs solares. *Procedia CIRP*, 80, 434-439 .
- Nguyen, D., Vo, B., & Vu, D.-L. (2016). Uma estratégia paralela para o lógico-probabilístico método baseado em cálculo para calcular a confiabilidade de dois terminais. *Quality and Reliability Engineering International*, 32, 2313-2327 .
- Nimura, T., & Nakashima, T. (2003). Análise de tradeoff multiobjetivo de desregulamentado transações de eletricidade. *International Journal of Electrical Power & Energy Systems*, 25, 179-185 .
- Oliveira, S., Wanner, EF, de Souza, SR, Bezerra, LC, & Stützel, T. (2019). O hi-indicador de pervolume como uma medida de desempenho em otimização dinâmica. *Conferência internacional sobre otimização evolutiva multicritério* (pp. 319-331). Springer .
- Ozkan, O., Ermis, M., & Bekmezci, I. (2019). Rede confiável de sensores multimídia sem fio projeto: Comparação de metaheurísticas híbridas e uma matemática. *Matemática Computacional e Aplicada*, 38, 106 .
- Pant, S., Kumar, A., Kishor, A., Anand, D., & Singh, SB (2015). Aplicação de um multi técnica de otimização de enxame de artigos de partículas objetivas para resolver o problema de otimização de confiabilidade. *Tecnologias de computação de última geração (NGCT)*, 2015 1ª conferência internacional em (pp. 1004-1007). IEEE .
- Pasandideh, SHR, Niaki, STA e Sharafzadeh, S. (2013). Otimizando um bi-objetivo modelo epq multiproducto com itens defeituosos, retrabalho e pedidos limitados: algoritmos Nsga-ii e mopso. *Journal of Manufacturing Systems*, 32, 764-770 .
- Praks, P., Kopustinskas, V., & Masera, M. (2017). Confiabilidade baseada em Monte-carlo e avaliação da capacidade de operação de um sistema de transmissão de gás natural devido a falhas aleatórias de componentes da rede. *Infraestrutura sustentável e resiliente*, 2, 97-107 .
- Provan, JS e Ball, MO (1983). A complexidade de contar cortes e computar o probabilidade de que um gráfico esteja conectado. *SIAM Journal on Computing*, 12, 777-788 .
- Rong-Hong, J. (1993). Projeto de redes confiáveis. *Computadores e Pesquisa Operacional*, 20, 25-34 .
- Roy, RK (2001). *Projeto de experimentos usando a abordagem Taguchi: 16 etapas para o produto e melhoria de processos*. John Wiley & Sons .
- Ruiwen, H., Jianhua, D., & Lai, LL (2017). Avaliação da confiabilidade da comunicação sistemas de proteção restrita usando modelos de rede de fluxo estocástico. *IEEE Transactions on Smart Grid*, 9, 2371-2381 .
- Salehi, S., Li, L., Shen, C.-C., Cimini, L., & Graybeal, J. (2018). Diferenciação de tráfego em wans densos com protocolo csma / eca-dr mac. *2018 IEEE 88ª conferência de tecnologia veicular (VTC-Fall)* (pp. 1-5). IEEE .
- Sherman, J. (2017). Pré-condicionamento generalizado e fluxo de custo mínimo não direcionado. *Anais do vigésimo oitavo simpósio anual ACM-SIAM sobre algoritmos discretos* (pp. 772-780). SIAM .
- Srivaree-ratana, C., Konak, A., & Smith, AE (2002). Estimativa da rede de todos os terminais confiabilidade usando uma rede neural artificial. *Computadores e Pesquisa Operacional*, 29, 849-868 .
- Suman, B. (2003). Algoritmos multiobjetivos baseados em recozimento simulado e seus aplicação para confiabilidade do sistema. *Otimização de Engenharia*, 35, 391-416 .
- Talbi, E.-G. (2009). *Metaheuristics: From design to implementation*, vol. 74 John Wiley & Filhos .
- Tatsis, VA e Parsopoulos, KE (2019). Adaptação de parâmetro dinâmico em metaheuristics usando aproximação de gradiente e pesquisa de linha. *Applied Soft Computing*, 74, 368-384 .
- Tavana, M., Li, Z., Mobin, M., Komaki, M., & Teymourian, E. (2016). Multi-objetivo Otimização do projeto de gráfico de controle usando NSGA-III e MOPSO aprimorado com DEA e TOPSIS. *Sistemas especialistas com aplicativos*, 50, 17-39 .
- Tripathi, PK, Bandyopadhyay, S., & Pal, SK (2007). Enxame de partículas multi-objetivo otimização com inércia variante do tempo e coeficientes de aceleração. *Ciências da Informação*, 177, 5033-5049 .
- Watcharasitthiwat, K., & Wardkein, P. (2009). Otimização de confiabilidade da topologia projeto de rede de comunicação usando uma otimização de colônia de formigas aprimorada. *Computadores e Engenharia Elétrica*, 35, 730-747 .
- Enquanto, L., Hingston, P., Barone, L., & Huband, S. (2006). Um algoritmo mais rápido para calcular hipervolume. *IEEE Transactions on Evolutionary Computation*, 10, 29-38 .

- Xu, J., Tu, Y., & Zeng, Z. (2012). Um modelo multiobjetivo não linear de dois níveis para o mínimo problema de fluxo de rede de custo em um projeto de construção em grande escala. *Mathematical Problems in Engineering*, 2012 .
- Sim, W.-C. (2013). Avaliando a confiabilidade de um novo multiestado com efeito de deterioração rede de fluxo. *Ciências da Informação*, 243, 75-85 .
- Sim, W.-C. (2015). Um algoritmo rápido para avaliações de confiabilidade de caminho mais rápidas em vários estados redes de fluxo. *IEEE Transactions on Reliability*, 64, 1175–1184 .
- Yeh, W.-C., & Chu, T.-C. (2018). Uma nova rede de fluxo de multi-estado e multi-distribuição e seu problema de otimização de confiabilidade. *Engenharia de confiabilidade e segurança do sistema*, 176, 209-217 .
- Zimmermann, H.-J. (2011). *Teoria dos conjuntos difusos - e suas aplicações*. Springer Science & Mídia Empresarial .
- Zitzler, E. (1999). Algoritmos evolutivos para otimização multiobjetivo: Métodos e aplicações, vol. 63. Citeseer.
- Zitzler, E., Brockhoff, D., & Thiele, L. (2007). O indicador de hipervolume revisitado: No projeto de indicadores compatíveis com Pareto via integração ponderada. *Conferência internacional sobre otimização evolutiva multicritério* (pp. 862–876). Springer .
- Zuev, KM, Wu, S., & Beck, JL (2015). Problema geral de confiabilidade de rede e seu solução eficiente por simulação de subconjunto. *Mecânica de Engenharia Probabilística*, 40, 25-35 .