

Modelo de otimização baseado em algoritmo Firefly para planejamento de redes de transporte óptico

Bruno Quirino de OLIVEIRA ^{1,2}, Marcos Antônio de SOUSA ^{1,2}, Flávio Henrique Teles VIEIRA ¹
¹ Escola de Engenharia Elétrica, Mecânica e de Computação, Universidade Federal de Goiás, Brasil

² Escola de Engenharia, Pontifícia Universidade Católica de Goiás, Brasil

brquirino@gmail.com

Resumo —O crescimento do tráfego de dados está aumentando seriamente

desafios para a OTN em termos de melhoria da eficiência de capacidade para atender aos novos requisitos de tráfego. Nessas circunstâncias, a tarefa de utilizar eficientemente os recursos disponíveis abre oportunidades para o desenvolvimento de uma variedade de técnicas de planejamento de rede. Este artigo apresenta um sistema de suporte à decisão para a rede de transporte óptico. É considerado o problema de planejamento da rede de transporte óptico onde uma matriz de interesse de tráfego entre os nós de demanda é especificada. A rede é modelada como um gráfico, por meio da abordagem de arco. Um problema de Programação Linear Inteira resolvido com um Algoritmo Firefly é proposto para o planejamento de redes, considerando a minimização de custos. As principais novidades do modelo ILP proposto é que ele realiza o projeto da rede óptica com a possibilidade de múltiplos destinos da matriz de tráfego e com alocação dinâmica da modularidade do sistema de transmissão. Para resolver o modelo de otimização ILP, são usados o algoritmo do firefly, o algoritmo genético e o método exato. Simulações são realizadas para verificar o desempenho dos algoritmos bioinspirados em relação ao método exato. Os resultados obtidos com o algoritmo do firefly superam os do algoritmo genético e se aproximam do resultado ótimo. Simulações são realizadas para verificar o desempenho dos algoritmos bioinspirados em relação ao método exato. Os resultados obtidos com o algoritmo do firefly superam os do algoritmo genético e se aproximam do resultado ótimo. Simulações são realizadas para verificar o desempenho dos algoritmos bioinspirados em relação ao método exato. Os resultados obtidos com o algoritmo do firefly superam os do algoritmo genético e se aproximam do resultado ótimo.

Índice **Termos** -artificial inteligência, comunicação
redes, algoritmos genéticos, redes de fibra óptica, otimização.

INTRODUÇÃO

O surgimento de novas tecnologias e serviços impôs mudanças substanciais nos sistemas de telecomunicações. Essas transformações estão acontecendo em grande escala para atender ao desenvolvimento da Internet das Coisas (IoT), computação em nuvem e sistemas de comunicações móveis de 4ª e 5ª geração. O impacto imediato da implantação e utilização dessas tecnologias surge com a necessidade de se ter uma rede de telecomunicações com alta capacidade de transmissão de dados [1-3].

A Rede de Transporte Ótico / Multiplexação por Divisão de Comprimento de Onda Densa (OTN / DWDM) permite uma infraestrutura de rede flexível com alta capacidade de transmissão. OTN também fornece gerenciamento de isolamento de falhas com técnicas avançadas para resolver quaisquer problemas operacionais [4]. Esta rede, aliada à versatilidade de multiplexação densa por divisão de comprimento de onda, minimiza a dificuldade de transporte de dados como na Multiplexação por Divisão de Tempo (TDM) dentro de redes Plesiochronous Digital Hierarchy (PDH) e Synchronous Digital Hierarchy (SDH) [5].

Nessas circunstâncias, a rede óptica está constantemente sendo submetida a inovações tecnológicas em

a fim de aproveitar melhor a infraestrutura atual para altas taxas de transmissão. Por outro lado, à medida que a rede se torna mais complexa, o uso eficiente de seus recursos torna-se um problema de grande preocupação. A pesquisa de algoritmos para otimizar a capacidade de recursos é uma direção promissora para melhorar os sistemas de apoio à decisão projetados para auxiliar no planejamento de redes [6].

O problema de planejamento de redes de transporte óptico (NP-hard) tem sido amplamente estudado na literatura [7]. O principal objetivo do planejamento é muitas vezes o mesmo: alocar e dimensionar os recursos disponíveis da forma mais eficiente possível em termos de orçamento, com modelos de otimização orientados para a minimização de custos. Basicamente, as metodologias podem ser diferenciadas de acordo com: quais são as tecnologias adotadas, os recursos mais relevantes para o que se deseja e uma faixa da rede a ser dimensionada [8].

Metaheurísticas inspiradas na natureza são ferramentas poderosas para resolver problemas de otimização combinatória NP-difíceis. Esses métodos são baseados em mecanismos existentes nos fenômenos biológicos da natureza [9]. Para redes ópticas, é possível destacar a utilização do algoritmo genético [10-12] e algoritmos baseados em enxame [13-15], como o algoritmo de Otimização de Enxame de Partículas (PSO) [16], colônia de formigas [17] e algoritmo do firefly [18].

Nesse cenário, é natural que diferentes problemas de otimização tenham sido propostos na literatura para o projeto de redes de transporte óptico. As metodologias aplicadas em cada caso são extremamente influenciadas pela cobertura da rede, pela tecnologia de transmissão a ser utilizada e pelas fontes de informação disponíveis [19-20]. No entanto, uma característica comum entre esses problemas de otimização é que eles absolutamente possuem uma matriz de tráfego que precisa ser roteada dos nós de origem para os nós de destino [21-22].

Com o crescimento explosivo das demandas, de diversas fontes de serviço, a atuação da rede de transporte diante de possíveis falhas tornou-se um campo de estudo de grande relevância. Em [23], um algoritmo heurístico baseado em Programação Linear Inteira (ILP [24] é proposto para resolver o problema de roteamento no contexto de redes OTN / DWDM. A aplicação envolve múltiplos cenários de rede em relação à topologia, distribuição de tráfego e formatos de transmissão disponíveis para quantificar os benefícios de eficiência da implantação de formatos de grade flexíveis.

Para o problema de alocação de fluxo em redes ópticas elásticas (EON) com proteção de caminho dedicada, o trabalho [25] propõe duas metaheurísticas baseadas em otimização, uma considerando o algoritmo de enxame de partículas e outra com busca tabu. O problema é modelado por programação linear inteira com respeito a dois tipos de otimização diferentes

critérios: com a utilização média e máxima do espectro. Ainda, em relação ao problema de roteamento em redes ópticas elásticas, no trabalho [26] foi proposto um método de otimização baseado no algoritmo Artificial Bee Colony (ABC) modelado por programação linear inteira. O método é desenvolvido para ser aplicado em grandes redes, trazendo extensos experimentos numéricos voltados para a avaliação de desempenho do algoritmo proposto em relação a métodos de referência que resolvem o mesmo problema.

O trabalho de [27] apresenta uma modelagem bi-objetivo usando programação linear inteira para o problema de atribuição de codificação e roteamento em redes ópticas OTN / WDM com proteção dedicada. Os objetivos são atingir o menor custo de roteamento e, ao mesmo tempo, empregar um número mínimo de nós de codificação. A formulação proposta utiliza um método de ponderação para combinar os dois objetivos em um método integrado e também fornece uma análise rigorosa na configuração dos coeficientes de ponderação para capturar a prioridade desejada dos objetivos individuais.

Este artigo tem como objetivo desenvolver um sistema de apoio à decisão para ser utilizado no planejamento estratégico de redes ópticas de transporte. Ele propõe um modelo de programação linear inteira 0-1, que é resolvido usando o método exato e os algoritmos genéticos e de pirilampus bioinspirados. O modelo seleciona caminhos ótimos de um conjunto de caminhos pré-candidatos disponíveis para o fluxo da matriz de tráfego prevista. O dimensionamento dos recursos é realizado visando um custo mínimo, que está relacionado às possibilidades de alocação de equipamentos de transmissão nos nós e alocação de link óptico e regeneradores nos links da rede.

Vale ressaltar que a modelagem proposta neste trabalho permite contemplar o atendimento de uma matriz de tráfego peculiar, ainda não abordada na literatura. As matrizes comumente avaliadas são compostas de pares de nós indicando o nó de origem e o nó de destino [21-23]. Neste trabalho, tanto o ILP desenvolvido quanto os algoritmos bioinspirados propostos para a resolução contemplam a possibilidade de aplicação de uma matriz de tráfego de demanda com seu nó de origem, mas com diversidade de nós de destino.

Esta abordagem pretende cobrir aqueles cenários de rede de transporte OTN / DWDM em que o operador do sistema tem a possibilidade de atender diversos pontos de demanda de longa distância dentro de sua área de atuação e poder transferir tráfego de overflow para outra rede que pode ser realizada por mais de um ponto de interconexão externo.

II. T E L E P R O B L E M

O problema de planejamento de redes de transporte óptico é complexo e difícil de resolver [8], [28]. As demandas da matriz de interesse de tráfego devem ser dispostas entre os nós por meio de links com capacidade associada. Nesse contexto, a ênfase do planejamento está em determinar a estratégia ótima para acomodar o conjunto de demandas.

Neste trabalho, o modelo de rede de fluxo (gráficos) [24] é utilizado para representar o problema de planejamento da rede de transporte óptico. A Fig. 1 mostra um exemplo de um gráfico, $G = (V, LINK, DEM)$, Onde V indica o conjunto de nós, $LINK$ o conjunto de arcos e DEM o conjunto de demandas a serem drenadas pela rede. Neste trabalho, a abordagem do caminho do arco é considerada [24].

Os principais elementos desta representação são:

Nós de demanda: Os nós de demanda são pontos de concentração e geradores de demanda para o serviço dos usuários do sistema. Esses nós devem estar fisicamente associados a um sistema de transmissão. Cada nó é identificado por um número [*eu*]. O exemplo de rede da Fig. 1 tem cinco nós de demanda e sete links.




Figura 1. Representação da rede de transporte - caminho de arco

Candidatos a links (arcos): cada link na rede representa a conexão entre dois nós de demanda. O fluxo de demanda drenado pelos links é utilizado para garantir o atendimento dos requisitos de demanda entre os nós da rede. Os links de fluxo de demanda que conectam todos os nós de demanda uns aos outros são identificados por um nome e um índice, como *link2*, que identifica o link que conecta os nós de demanda 1 e 5. A capacidade total de cada link, representada pela capacidade do equipamento de transmissão alocada, deve ser capaz de atender ao fluxo de demanda escolhido para ser alienado por aquele link. A escolha da capacidade de cada link é representada por uma variável de decisão do tipo inteiro binário, por exemplo, $X[link2, n]$, que representa a escolha (ou não) de um sistema de transmissão modular [*n*] para ser alocado em *link2*.

Demanda prevista: um dos objetivos do projeto da rede é atender à demanda entre os nós da rede. Cada demanda se caracteriza por ser o nosso destino e o volume de tráfego que deve ser encaminhado pela rede. Este volume de tráfego pode ser expresso em múltiplos de alguma unidade básica de roteamento ou mesmo em termos da taxa de transmissão necessária. Entre os nós finais, um nó representa o nó de origem da demanda e o outro nó o nó de destino. Na rede de exemplo da Fig. 1, dois valores de demanda previstos são indicados: *dem1* (do nó 1 ao nó 5) e *dem2* (do nó 2 ao nó 5).

Caminhos candidatos: um caminho é definido por uma sequência de nós adjacentes sem repetição por onde um fluxo de demanda pode passar, cada fluxo de demanda podendo usar um ou mais caminhos distintos. Para cada demanda prevista entre dois nós da rede, um conjunto de caminhos é especificado que pode ser usado para fluir a demanda de seu nó de origem para seu nó de destino. Para o exemplo de rede da Fig. 1, onde duas demandas são especificadas, os possíveis conjuntos de caminhos para atender às demandas *dem1* e *dem2* são indicados na Tabela I. Observe que o conjunto de caminhos na Tabela I não está completo, sendo apenas

exemplos de caminhos para *d1* e *d2* demandas. Essa escolha é feita por meio de variáveis de decisão de tipo binário, $Y[demanda, caminho]$, que especifica a escolha (ou não) do caminho (por exemplo, caminho *p1*) para fluir a demanda (por exemplo, demanda *dem1*).

Ligado ao caminho de escolha (p_1, \dots, p_k) para fluir a demanda prevista $[k] \cdot DEM$ (população inicial, acontece em duas etapas, sendo a etapa do $Y_{[j][k]}$ é em $dem_{[j]}$. Com o fluxo de demanda total em $ligação_{[eu]}$ sua modularidade $Bone_{[noj]}$ variáveis não muda. Assim, um ponto de corte no n_j variáveis

$X_{[noj]}$ é escolhido. A estrutura criada para as variáveis

$Y_{[j][k]}$ na Fig. 2 tem TN multiplicidade de nós de destino para cada demanda. A escolha de cada caminho de fluxo deve respeitar este multiplicidade. O pseudocódigo do Algoritmo Genético (AG) é apresentado como Algoritmo 1. Seus operadores são descritos mais adiante no texto.

UMA LGORITMO 1. S TANDARD G ENÉTICO UMA LGORITMO	
Step01.	Inicializar parâmetros de algoritmo Número de geração ($nGer$) Probabilidade de cruzamento (Pc) Probabilidade de mutação (PM)
Step02.	Função objetiva $f(x)$, $x = (x_1, \dots, x_n)$
Step03.	Gera população inicial P de cromossomos X_{eu} $i = 1, 2, \dots, n$
Step04.	A função de aptidão é determinada por $f(X_{eu})$
Step05.	Enquanto ($t < nGer$) Executa a seleção do torneio Aplicar mecanismo de crossover com probabilidade Pc Aplicar mecanismo de mutação com probabilidade PM
Step06.	Classifique os indivíduos e encontre a melhor solução global Encerre enquanto
Step07.	

População inicial: o número de indivíduos que farão parte da população inicial é definido pelo planejador. O tamanho desta população é mantido ao longo do processo iterativo, e cada indivíduo da população é criado em duas etapas:

- 1 *Etapas do $Y_{[j][k]}$ variáveis*: Consiste em alocar aleatoriamente, para cada demanda, um dos disponíveis caminhos para o fluxo. Assim, é possível verificar a vazão total que está sendo drenada em cada link.
- 2 *Etapas do $X_{[noj]}$ variáveis*: Com os fluxos de cada link calculado na etapa anterior, a modularidade é atribuído a cada arco (variável $X_{[noj]}$ assumir valor 1) igual ou maior que a vazão total. Para aqueles casos em que o fluxo do link é identificado como nulo, o variável $X_{[noj]}$ é definido como 0.

Classificação de soluções (seleção): a população inicial representa um conjunto de soluções viáveis para o problema apresentado. Em seguida, é necessário que cada elemento desse conjunto seja avaliado quantitativamente para que a qualidade de cada solução possa ser definida. Para o algoritmo genético desenvolvido, a função objetivo de ILP 0-1 é usada como uma função de aptidão. Desta forma, as soluções têm sua qualidade avaliada de acordo com o custo apresentado. Portanto, quanto menor o custo, melhor o indivíduo.

Agora, para o processo de crossover, é necessário selecionar os indivíduos a serem cruzados. A seleção do torneio é realizada desenhando dois conjuntos de soluções retirados da população atual. Em cada set, é realizado um torneio onde apenas os melhores são selecionados. Com o melhor indivíduo de cada conjunto selecionado, há alguns indivíduos para o crossover. Este processo de seleção é realizado para cada crossover que ocorrerá em cada geração do algoritmo.

O número de indivíduos retirados da população inicial também é definido pelo planejador. Porém, quanto maior o conjunto, maior a pressão de seleção, pois aumentam as chances de que os mesmos indivíduos sejam selecionados e esse fato diminui a diversidade populacional.

Crossover: O cruzamento implementado, bem como o

corrente de $Y_{[j][k]}$ variáveis, com a restrição de que caminhos de uma mesma demanda não possam ser separados por este ponto de corte.

Na verdade, esse processo poderia representar a duplicação da demanda dentro da rede em relação ao modelo proposto, e isso tornaria o indivíduo inevitavelmente inviável. Assim, as possibilidades de pontos de corte são limitadas ao número de demandas a serem drenadas na rede, respeitando o número de caminhos candidatos para cada demanda.

O ponto de corte é responsável pela divisão da porção $Y_{[j][k]}$ do indivíduo em duas partes. A parte esquerda do primeiro indivíduo será concatenada com a parte direita de o segundo e vice-versa. Dessa forma, são gerados dois filhos, ou seja, duas novas soluções de rede possíveis, e essas tendem a ser melhores que as duas anteriores.

Após o procedimento de crossover executado na solução parte $Y_{[j][k]}$ cada filho gerado tem seu $X_{[noj]}$ parcela criada, permitindo sua avaliação. Apenas uma criança pode permanecer na próxima geração. A escolha do indivíduo segue a seguinte prioridade:

1. duas soluções viáveis: o indivíduo criança de menor custo irá compor a próxima geração.
2. apenas uma solução viável: o indivíduo criança viável é selecionado.
3. nenhuma solução viável: o operador de crossover é executado novamente com outros pontos de corte até que uma solução viável, ou seja, um indivíduo criança viável seja encontrado.

Isto é vale lembrar que o operador de crossover descrito acima é controlado por uma probabilidade de ocorrência definido pelo planejador. O operador de cruzamento só acontece quando ocorre o se a probabilidade for atendida. Portanto, no caso de não haver a próxima cruzamento, o indivíduo progenitor é simplesmente mantido no destino da demanda e geração. O processo de crossover pode alterar tanto o no caminho utilizado para seu fluxo. indivíduos gerados no processo de crossover) Mutação: o novo módulo de população (composto de novas pequenas podem sofrer demanda. Este procedimento é realizado para garantir a convergência da mudanças aleatórias nos caminhos escolhidos para fluir cada diversidade ao longo população para um mínimo local. das gerações, reduzindo a probabilidade de

A mutação não ocorre em todos os indivíduos. Um controle de probabilidade. Uma vez de ocorrência também é definido para realizar esta desconstrução do que uma taxa de probabilidade muito alta pode representar um operador da solução ao longo das gerações. variáveis. Consequentemente, A mutação também ocorre na porção do $Y_{[j][k]}$ a porção $X_{[noj]}$ precisa ser etapas de criação. A mutação só muda o caminho, definido novamente, como realizado em uma da população inicial não modificar o mas faz destino da demanda.

V. FIREFLY COMPUTACIONAL E IMPLEMENTAÇÃO

O algoritmo do firefly é um dos algoritmos baseados em enxame conhecidos, tendo diferentes tipos de aplicações [30]. Este algoritmo é uma metaheurística inspirada na natureza para resolver problemas contínuos de otimização, especialmente problemas NP-difíceis e foi motivada pela simulação do comportamento social de vaga-lumes. É possível utilizá-los para formular algoritmos de otimização, pois o piscar da luz pode ser utilizado de forma que esteja associado ao objetivo

função do problema considerado para obter soluções ótimas [31].

Para problemas de maximização, o brilho pode ser proporcional ao valor da função objetivo. Para problemas de minimização, o brilho pode ser o inverso do valor da função objetivo.

No algoritmo do firefly, existem duas questões importantes: a variação da intensidade da luz e a formulação da atratividade. Para simplificar, pode-se supor que a atratividade do vaga-lume é determinada por seu brilho, que por sua vez está associado à função objetivo codificada. O Algoritmo 2 apresenta as etapas básicas do algoritmo do firefly.

UMA LGORITMO 2. S TANDARD F IREFLY UMA LGORITMO	
Step01.	Inicializar parâmetros de algoritmo Número de vaga-lumes (n) Número de geração ($nGer$) Coeficiente de absorção de luz (γ) Atratividade (α_0) Valor alfa (α)
Step02.	Função objetiva $f(x)$, $x = (x_1, \dots, x_d)^T$
Step03.	Gera população inicial P de vaga-lumes $x_{eu}(i = 1, 2, \dots, n)$
Step04.	Intensidade da luz eu_i no x_i é determinado por $f(x_{eu})$
Step05.	Enquanto ($t < nGer$) Para cada $x_{eu} \in P$ Para cada $x_j \in P$ Se ($eu_{eu} < eu_j$) então mova x_{eu} para x_j Fim se Variar β com a distancia r via $\exp[-\gamma r]$ Avalie as soluções e atualize a intensidade da luz para j Fim para eu
Step06.	Classifique os vaga-lumes e encontre a melhor solução global Encerre enquanto
Step07.	

A função de atratividade $\alpha(r)$ pode ser qualquer função monotonicamente decrescente, como a seguinte forma generalizada dada por:

$$\alpha(r) = \alpha_0 e^{-\gamma r^m} \quad (5)$$

Onde α_0 é a atratividade em $r = 0$ e r é a distância entre dois vaga-lumes.

Uma vez que geralmente é mais rápido calcular $1/(1+r^2)$ do que a função exponencial [10] (5) pode ser aproximada como a equação (6).

$$\alpha(r) = \frac{\alpha_0}{1 + r^2} \quad (6)$$

A distância entre quaisquer dois vaga-lumes eu e j , no posição x_{eu} e x_j , respectivamente, pode ser definida como uma distância cartesiana, conforme (7), onde x_{ik} é o componente k do coordenada espacial x_{eu} do vaga-lume eu e d denota o número de dimensões.

$$r_{eu,j} = \sqrt{\sum_{k=1}^d (x_{ik} - x_{jk})^2} \quad (7)$$

O movimento aleatório de um vaga-lume eu para outro vaga-lume mais brilhante j é determinado por (8), onde o segundo termo considera a atratividade do vaga-lume, o terceiro termo é aleatório com α . Começar um parâmetro aleatório, e α_{eu} é um vetor de números aleatórios extraído de uma distribuição gaussiana ou uma distribuição uniforme.

$$x_{eu} = x_{eu} + \alpha_0 e^{-\gamma r_{eu,j}^m} (x_{eu} - x_j) + \alpha_{eu} \quad (8)$$

De uma forma mais simples, α_{eu} pode ser substituído por $rand \cdot 1/2$, Onde $rand$ um gerador de números aleatórios distribuído uniformemente em $[0, 1]$.

Para a maioria dos aplicativos $\alpha = 1$ e $\alpha \in [0, 1]$. Na prática, o coeficiente de absorção de luz γ varia de 0,1 a 10. Este parâmetro descreve a variação na atratividade e seu valor é responsável pela velocidade de convergência do algoritmo [9].

O firefly foi originalmente desenvolvido para resolver problemas de otimização contínua e não pode ser aplicado diretamente para resolver problemas discretos. Os principais desafios de usar o vaga-lume para resolver problemas discretos estão no cálculo da distância entre dois vaga-lumes discretos e como eles se moverão [32].

A distância entre dois vaga-lumes é definida pela distância entre a permutação de suas sequências. Existem duas maneiras possíveis de medir a distância entre qualquer dois vaga-lumes eu e j , nas posições x_{eu} e x_j : (a) a distância de Hamming [33] e (b) a distância de troca [34]. O

A distância de Hamming entre duas permutações é o número de elementos não correspondentes na sequência. A distância de troca é o número de trocas mínimas necessárias para uma permutação para obter a outra.

A atração e o movimento devem ser implementados e interpretados para o vaga-lume discreto da mesma forma que é feito no algoritmo do vaga-lume contínuo. Assim, o movimento dado em (8) é dividido em duas subetapas: *passo β* e *α -step*

como mostrado em (9) e (10), respectivamente.

$$x_{eu} = \alpha(r) (x_{eu} - x_j) \quad (9)$$

$$x_{eu} = x_{eu} + \alpha(rand \cdot 1/2) \quad (10)$$

Os passos da atração α e β não são intercambiáveis, então o *passo β* deve ser calculado antes do *α -step* enquanto a nova posição é encontrada. O *passo β* sempre traz o vaga-lume j mais perto do vaga-lume eu . Em outras palavras, depois de aplicar o *passo β* em um vaga-lume em direção ao outro, sua distância é sempre diminuída, e a diminuição é proporcional à sua distância anterior. Para isso, a distância de Hamming é usada como a função de distância. Isso significa que para que a permutação se aproxime da outra permutação, a quantidade de seus elementos comuns deve aumentar. Em primeiro lugar, no *passo β* processo, o que é comum em ambos os vaga-lumes é extraído.

Em segundo lugar, é necessário preencher as lacunas em relação à distância anterior das permutações. Isso pode ser alcançado com a probabilidade (11):

$$\alpha = \frac{1}{1 + d_{eu,j}^2} \quad (11)$$

Onde $d_{eu,j}$ é a distância de Hamming entre vaga-lumes eu e j .

Através da probabilidade α um elemento vaga-lume eu ou j será inserido para o novo vaga-lume. Depois de calcular α um número aleatório $rand()$ é gerado no intervalo $[0, 1]$. Se $rand() < \alpha$ então a inserção é realizada com o elemento de eu , diferente de j . Este processo é realizado até que todas as lacunas no novo vaga-lume sejam preenchidas. Vale ressaltar que após cada preenchimento deve-se verificar a nova distância para a próxima inserção do gap.

Depois de preencher todas as lacunas, o *α -step* é executado, o que é mais simples do que *passo β* . Esta etapa mudará os elementos desta nova formação para os elementos vizinhos. A menor mudança corresponde a dois elementos.

Existem duas maneiras de aplicar o *α -step*: faça um α *acaso()* para realizar muitas trocas de dois elementos escolhidos aleatoriamente ou escolher muitos elementos através

• . *acaso()* e embaralhe suas posições. A primeira opção é mais fácil de implementar, mas os resultados não são tão bons quanto a segunda [35]. O • *acaso()* representa uma etapa máxima permitida para a permutação, que consiste em n elementos Para conseguir isso, é necessário • ser do conjunto $\{1, \dots, n\}$. Então • $= 1$ significa que nenhuma etapa é feita e • $= n$

significa embaralhar todos os elementos da permutação.

As rotinas de codificação, geração inicial da população e classificação seguem o processo descrito na Seção GA Implementação Computacional. A seguir está uma descrição da rotina de movimento do firefly.

Movimento do pirilampo: após a criação da população do pirilampo, o valor da intensidade da luz (custo), que é obtido avaliando a função objetivo do ILP 0-1. Com isso, é possível avaliar a qualidade da solução (ranking) de acordo com o custo apresentado. Assim, quanto menor o custo, melhor o indivíduo (maior intensidade de luz).

A partir desse conjunto de soluções contendo vaga-lumes de menor custo para o maior custo é criada uma cópia e em que os vaga-lumes são posicionados do maior para o menor custo (realizado para obter maior diversidade), para entrar no estágio de movimento. O primeiro vaga-lume eu_i é comparado com todos os vaga-lumes j (cópia de). Este procedimento é realizado com o firefly

eu_i até vaga-lume eu_n . Se o vaga-lume selecionado j tem uma intensidade menor, ou seja, maior custo de implementação, ele será movido para o vaga-lume eu_i , que tem a maior intensidade e este vaga-lume será colocado no vaga-lume eu_i posição.

Para realizar o movimento, primeiro é necessário calcular a distância entre os vaga-lumes. Para este cálculo, a distância de Hamming será usada. O movimento é aplicado a as variáveis binárias do firefly ($Y_{[i][k]}$). Um exemplo com um sistema de transmissão de três módulos ($n = 3$) e cinco caminhos candidatos para fluir cada demanda ($k = 5$) cada TN destino é mostrado na Fig. 3.

No exemplo, a distância de Hamming entre o vaga-lume eu_i e vaga-lume j é 2 (demandas fluídas por caminhos diferentes em $dem2$ e $dem4$). Para realizar o movimento, o *passo* β é executado, ou seja, um novo vaga-lume *passo* β (1) é criado, mantendo as demandas com caminhos idênticos ($dem1$ e $dem3$). Depois que as lacunas são preenchidas, a probabilidade β é calculado ou cada lacuna e compara este valor com o número aleatório $rand()$

gerado no intervalo $[0, 1]$. Observe que β é controlado pelo coeficiente de absorção de luz (γ) definido pelo usuário e distância de Hamming. Se $rand() < \beta$ então a inserção é realizada com o vaga-lume eu_i elemento, caso contrário, o firefly j .

No *passo* β (2) pode-se verificar que $dem2$ foi selecionado do firefly j , e para $dem4$ vaga-lume, eu_i foi escolhido.

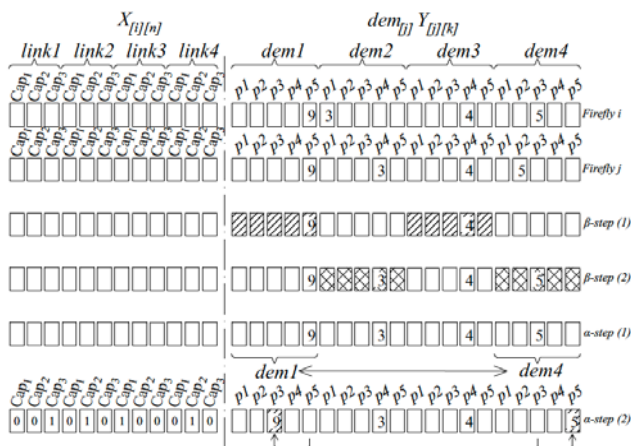


Figura 3. Movimento do Firefly

Então o α -step será realizado. A quantidade máxima de (α -step) permutações são controladas por α parâmetro, previamente definido. Assim, a quantidade de permutações é determinada arbitrariamente pela escolha de um valor aleatório inteiro gerado no $[1, \gamma]$ intervalo e após, as demandas para realização da permutação são escolhidas, também de forma aleatória. No exemplo, o α o valor era 2. Em α -step (1) da Fig. 3 a quantidade de permutações foi igual a 1 e as demandas escolhidas para a troca foram $dem1$ e $dem4$. O que será alterado é o caminho da demanda a fluir e não os valores das demandas, para que $dem1$ que estava fluindo sua demanda de 9 *Gbps*

pelo caminho p_5 , agora é drenado por p_3 , qual foi o caminho que drenou $dem1$ demanda de 5 *Gbps*. E em $dem4$ a troca foi realizada de p_3 para p_5

Uma vez o *passo* β e α -step procedimentos são realizados, o o fluxo total de cada link pode ser calculado e, assim, alocar seu modularidade ($X_{[n]}$ etapa de variáveis). Caso o vaga-lume seja inviável, o processo de movimentação é realizado novamente, até a criação de um vaga-lume viável. Após a conclusão da comparação / movimentação de todos os vaga-lumes, uma nova classificação é realizada.

VI. E AVALIADO S CENÁRIO

A metodologia pode ser aplicada a diferentes cenários da rede de transporte óptico, diferentes tipos de tecnologias de transmissão e diferentes matrizes de tráfego. Naturalmente, para as mesmas variáveis de entrada, se os parâmetros dos dados forem diferentes, por exemplo, os caminhos pré-computados para cada demanda, as soluções alcançadas também mudarão.

Com o objetivo de avaliar um cenário de aplicação semelhante à realidade, a metodologia utilizada para a elaboração dos dados da rede foi a integração da equipe com uma empresa de telecomunicações. Nessa parceria, foram coletadas informações relevantes, como localização dos pontos de demanda, distâncias entre as localidades, topologia da rede, custos dos equipamentos e rede óptica.

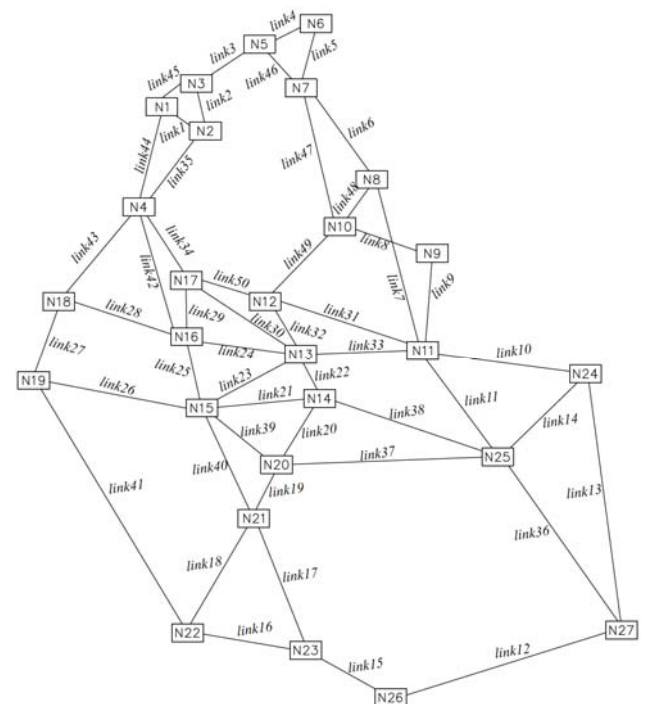


Figura 4. Rede backbone OTN / DWDM

A rede OTN / DWDM estudada pode assumir três modelos hierárquicos, com capacidade de transmissão de 40, 100 e 400 *Gbps*. A rede real levantada é composta por 27

nós individuais e 50 links. A Fig. 4 mostra a topologia da rede, incluindo os possíveis links a serem alocados e escalados.

O interesse de tráfego é definido a partir das cidades onde a operadora atende, mesclando áreas de concessão e expansão. Cada cidade (nó de demanda) possui uma previsão de atendimento aos clientes daquela região. Uma particularidade dessa rede é que o tráfego gerado em cada nó de demanda (nó fonte) precisa ser drenado para os pontos de comunicação (ou estouro) com outra WAN (Wide Area Network). Na rede da Figura 4, os nós N26 e N27 são os nós de destino.

T CAPAZ II. OTN / DWDM NETWORK DEMANDS

Demanda	(Gbps)	Demanda	(Gbps)
dem1	13	dem15	4
dem2	0,5	dem16	10
dem3	1	dem17	22,5
dem4	5	dem18	11,5
dem5	0,5	dem19	12,5
dem6	37,5	dem20	7,5
dem7	1,5	dem21	19
dem8	2,5	dem22	3,5
dem9	12	dem23	25
dem10	2,5	dem24	30
dem11	7,5	dem25	15
dem12	4	dem26	13
dem13	20	dem27	30
dem14	50		

A rede apresenta um total de 27 demandas previstas que devem ser integralmente atendidas e direcionadas aos nós de destino. A Tabela II lista um exemplo de uma matriz de tráfego gerada aleatoriamente no [0,5, 50] Gbps faixa.

Algumas características da modelagem que são obedecidas na avaliação da rede da Fig. 4: as demandas e os enlaces obedecem a mesma forma de roteamento, sendo bidirecionais; a capacidade dos links é explícita; todos os caminhos existentes podem ser usados e a demanda prevista não pode ser drenada por mais de um caminho.

O custo da rede foi determinado a partir de uma pesquisa detalhada de cada serviço e ativos usados para implementar um link. Depois de coletar os custos separados de cada item, o custo total de implantação de cada link com os três módulos OTN / DWDM sendo avaliados (40, 100, 400 Gbps) estava

calculado. Os custos dos regeneradores também foram especificados de acordo com a modularidade da transmissão e seu alcance. A Tabela III apresenta esses valores. Os valores usados são relativos. O custo dos 40 Gbps modularidade O sistema OTN / DWDM (\$ 79.000,00) é usado como base. O custo da rede óptica considerado representa um cálculo consolidado do custo médio da rede por quilômetro, que é 0,00012.

T CAPAZ III. COSTS OF OTN / DWDM SYSTEMS

Modularidade (Gbps)	Distância	Custo
40	Até 80 Km	1,00
	Maior que 80 Km	1,32
100	Até 80 Km	1,90
	Maior que 80 Km	2,22
400	Até 80 Km	3,92
	Maior que 80 Km	4,24

O algoritmo genético e o algoritmo do firefly são implementados no software MATLAB®, rodando em um microcomputador com ambiente macOS®, Intel Core i5

Processador de 2,3 GHz e 8 GB de RAM. O desempenho da abordagem apresentada foi verificado computacionalmente, e os resultados foram comparados com o método exato, onde o *intlinprog* solver foi usado, que faz uso do método de solução branch-and-bound (B&B) [36].

O experimento inicial foi realizado no modelo ILP exato para verificar a influência do número de caminhos candidatos para cada demanda. A qualidade da solução obtida, bem como o esforço computacional necessário, são avaliados. A Tabela IV apresenta os resultados de acordo com o número de caminhos candidatos para cada demanda entre $k = 10$ (5 caminhos para cada destino) e $k = 20$ (10 caminhos para cada destino).

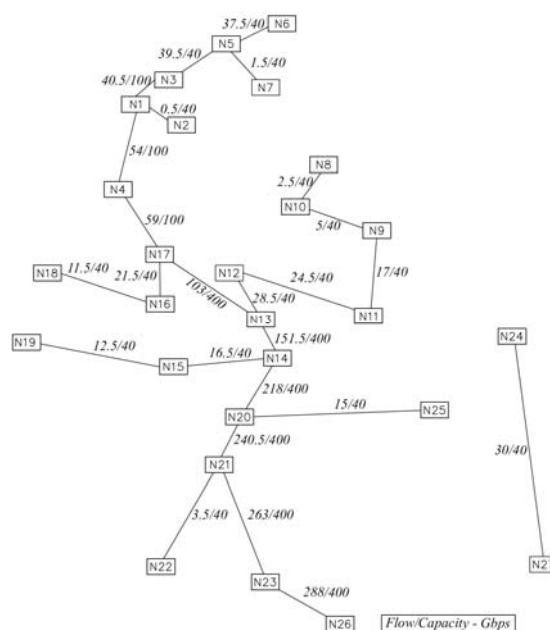
A métrica usada para o *k-caminhos* a aplicação foi a geração automática usando uma versão modificada do algoritmo k-shortest [37-38]. A distância total entre o nó de origem e o nó de destino, em *km*, é usado como um fator decisivo.

T CAPAZ 4. E MÉTODO EXATO COMPARISON

Número de Candidato Caminhos	Custo	Total Capacidade (Gbps)	Capacidade Usada (%)	Execução Tempo (s)
10	70,84	3340	47,40	2460
12	68,07	3040	52,20	56077
14	67,30	3340	49,70	35566
16	67,21	3340	50,30	64376
18	67,21	3340	50,30	290739
20	67,21	3340	50,30	318140

Pode-se observar na Tabela IV que a solução ótima e o tempo de execução são fortemente influenciados pelos caminhos pré-computados. Isso demonstra que a grande solução de rede obtida com métodos exatos exige um grande esforço computacional e, conseqüentemente, um alto valor no processamento do tempo. Para 16, 18 e 20 caminhos candidatos a solução é a mesma, entretanto, o tempo de processamento aumenta consideravelmente.

A topologia da rede com a solução ótima (método exato) para $k = 16, 18$ e 20 podem ser verificados na Fig. 5. Cada elo escolhido indica os fluxos drenados e a capacidade alocada (fluxo / capacidade) em Gbps.

Figura 5. Rede de soluções para $k = 16, 18$ e 20

A rede de soluções priorizou o fluxo de demandas através do nó N26. No resultado obtido dos 50 links candidatos, foram instalados 25, sendo 16 links de 40 Gbps, 3 links de 100 Gbps e 6 links de 400 Gbps. A capacidade utilizada da solução de rede é de 50,30%.





A Tabela V apresenta a comparação de desempenho entre o algoritmo genético e o algoritmo do firefly com a mudança no número de caminhos candidatos.

T CAPAZ V. COMPARISON OF BIO-INSPIRED METHODS

Número de Candidato Caminhos	Método	Custo	Exato Método (Custo)	Lacuna
10	Genético Algoritmo	79,14	70,84	11,72%
	Firefly	70,84		00,00%
12	Genético Algoritmo	78,16	68,07	14,82%
	Firefly	70,32		03,30%
14	Genético Algoritmo	73,79	67,30	09,64%
	Firefly	67,30		00,00%
16	Genético Algoritmo	78,84	67,21	17,30%
	Firefly	69,46		03,35%
18	Genético Algoritmo	80,70	67,21	20,07%
	Firefly	69,55		03,48%
20	Genético Algoritmo	78,82	67,21	17,27%
	Firefly	69,85		03,92%

O Gap representa a porcentagem da solução que está acima do valor ideal. O critério de parada foi o tempo de execução de 3600 segundos. Para o algoritmo genético, foram utilizados 100 indivíduos da população, 0,6 probabilidade de cruzamento e 0,10 probabilidade de mutação. No vaga-lume, foram usados 100 vaga-lumes populacionais, o valor de β era 1, α com valor 8 e 0,1 para o coeficiente de absorção de luz (γ).

As Fig. 6, 7, 8 e 9 apresentam a comparação para cada caso da Tabela V (variação do número de caminhos candidatos) do custo em função do tempo de execução. O algoritmo do firefly mostrou-se mais eficaz em todos os casos, com ênfase em 10 e 14 caminhos candidatos, onde o firefly obteve o mesmo valor do método exato branch-and-bound. O algoritmo do firefly na maioria dos casos atinge a convergência antes de 500 segundos. A melhor solução de algoritmo genético foi para 14 caminhos candidatos, com 09,64% maior que o valor ótimo. Os resultados do algoritmo genético foram em média 15,14% superiores ao método exato, e o do vaga-lume com 2,34%.

Figura 6. A convergência de algoritmos para $k = 10$ Figura 7. A convergência de algoritmos para $k = 14$ Figura 8. A convergência de algoritmos para $k = 18$ Figura 9. A convergência de algoritmos para $k = 20$

A Tabela VI apresenta outra comparação entre o algoritmo genético e os métodos do pirilampo, onde para cada um foram realizadas 10 repetições (cada algoritmo foi executado 10 vezes), e o critério de parada foi o número de gerações (50). Para as demandas esperadas, k = Foram gerados 10 caminhos (5 para cada destino). Esta k valor permite que uma boa variedade de combinações de caminhos seja analisada mantendo o tempo em um valor de processamento relativamente baixo (como visto na Tabela IV).

T CAPAZ VI. COMPARISON OF FIREFLY AND GENETIC ALGORITHM

TAPAZ VI. COMPARISON DEY FIREFLY E GENETICO DUMA LGORITMO				
Método	Algoritmo genético		Firefly	
Réplica	Custo	Tempo (s)	Custo	Tempo (s)
1	80,98	34	70,84	143
2	78,52	33	73,09	145
3	79,72	38	73,32	139
4	77,99	31	73,09	141
5	79,47	31	73,30	141
6	80,66	32	73,23	134
7	81,85	30	73,23	138
8	81,58	36	73,18	141
9	80,34	35	73,32	144
10	82,84	29	73,09	148

Os dois métodos apresentam valores baixos em termos de tempo de processamento de cada réplica, destacando que o algoritmo genético forneceu os menores valores. Porém, em relação ao custo de implantação da rede, o algoritmo do firefly se mostrou mais eficaz em todas as réplicas, com a réplica 1 obtendo o

mesmo valor do método exato.

A Fig. 10 mostra os custos comparativos desses métodos em relação ao número de gerações (com $k = 10$ caminhos gerados). Pode-se observar que ambos os métodos nas primeiras gerações apresentam uma queda elevada, mas o vaga-lume apresenta melhores valores.




Figura 10. Comparativo de convergência para $k = 10$

A Tabela VII apresenta a comparação entre os três métodos para 10 caminhos candidatos, tomando o número de gerações como critério de parada.

T CAPAZ VII. C OMPARISON ENTRE M ÉTODOS PARA 10 P ATHS

Método	Exato	Genético Algoritmo	Firefly
Melhor Custo	70,84	77,99	70,84
Pior Custo	-	82,84	73,32
Custo médio	-	80,39	72,97
Gap médio	-	13,52%	3,00%
Tempo (s) de execução	2460	329	1414

O tempo de execução apresentado para os algoritmos genético e vaga-lume é a soma das 10 réplicas realizadas. O desempenho em termos de tempo computacional necessário para encontrar a solução com o método exato apresentou um valor alto quando comparado aos outros dois métodos.

O algoritmo genético apesar de apresentar excelentes resultados em termos de tempo, a solução teve um valor de implantação de rede maior (aproximadamente 10% maior que a solução ótima). O algoritmo do firefly se destaca por sua eficiência, pois atingiu o mesmo valor ótimo do método exato com um tempo de execução menor (cerca de 42,50%).

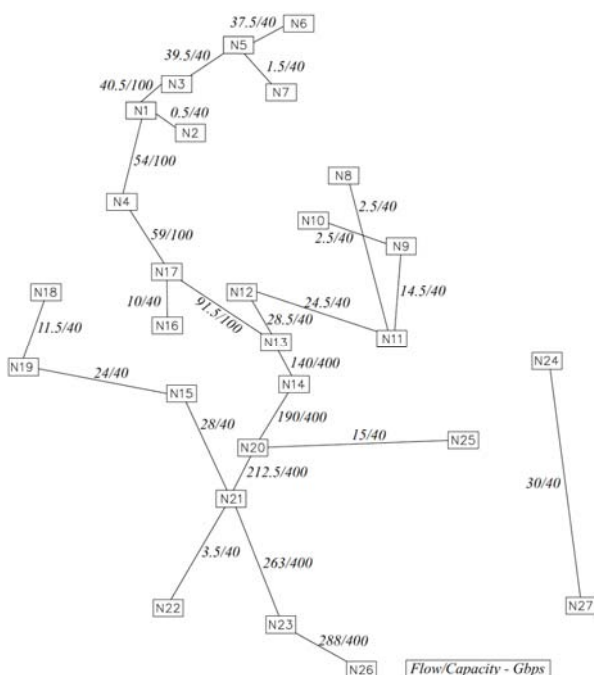


Figura 11. Rede de soluções para $k = 10$

A topologia da rede com a solução ótima (método exato e firefly), para $k = 10$, obtido com as simulações, pode ser verificado na Fig. 11.

A rede de soluções também priorizou as demandas a serem drenadas pelo nó N26. No resultado obtido dos 50 links candidatos, 25 foram instalados, sendo 16 links de 40 *Gbps*, 3 links de 100 *Gbps* e 6 links de 400 *Gbps*. A rede de soluções para $k = 10$ (Fig. 11) é 5,40% mais caro do que a solução de rede para $k = 16$, 18 e 20 (Fig. 5). Como os sistemas OTN / DWDM alocados são iguais nas duas redes, a diferença orçamentária se deve ao custo da rede e / ou regeneradores devido às mudanças nos nós de demanda 8, 15 e 18 de serviço. Embora as duas redes tenham a mesma capacidade total disponível (Tabela IV), a rede da Fig. 11 mostra uma lacuna maior do que a apresentada na Fig. 5.

VII. CONCLUSÃO

A constante evolução da demanda de telecomunicações tem obrigado as operadoras do setor a buscarem novas soluções para o planejamento de suas redes. Os objetivos a serem alcançados podem ser atendidos por técnicas de otimização que podem combinar minimização de custos e maximização de receita.

Este trabalho apresentou uma proposta de planejamento estratégico voltada para a minimização de custos com infraestrutura de rede de transporte óptico OTN / DWDM. A rede é vista como um gráfico e, seguindo a abordagem do caminho de arco, a modelagem foi traduzida como um problema completo de programação linear com variáveis binárias, que obedece às restrições de demanda, capacidade técnica dos equipamentos e requisitos de exclusividade de atendimento. As técnicas de resolução utilizadas para resolver o modelo de otimização ILP 0-1 foram o algoritmo genético e o algoritmo do pirilampo.

Os resultados preliminares obtidos em relação ao desenvolvimento computacional da ferramenta de atuação estamos encorajando, destacando a facilidade de adaptação do modelo para atender a novos requisitos e / ou especificidades de rede e tecnologia a serem avaliadas. A modelagem proposta neste trabalho apresenta as seguintes diferenças mais relevantes: projeto de rede óptica com matriz de demanda com múltiplos destinos; e alocação dinâmica de modularidade de sistemas de transmissão com agregação de tráfego mais eficiente.

A qualidade da solução e o tempo computacional são fortemente influenciados pelo número de caminhos candidatos. O algoritmo genético, mesmo com os menores tempos de processamento, apresentou as soluções mais caras. Em relação ao algoritmo do firefly, destaca-se pelos bons resultados tanto em termos de solução quanto de tempo computacional.

As atividades que podem ser apontadas como extensões deste trabalho são: análise por meio de modelagem fuzzy para representar dados imprecisos, incluindo cenários de demanda mais otimistas; e estudos sobre a possibilidade de modelagem multiobjetivo, comparando custo mínimo e capacidade máxima de rede.

REFERÊNCIAS

- [1] A. Kumar, M. Gupta, "Uma revisão sobre as atividades do sistema de comunicação móvel de quinta geração", Alexandria Engineering Journal, 2017. doi: 10.1016 / j.aej.2017.01.043.
- [2] S. Mumtaz, A. Morgado, KMS Huq, J. Rodriguez, "Um estudo das tecnologias 5G: regulamentar, normalização e industrial

- perspectivas, "Digital Communications and Networks, 2017. doi: 10.1016 / j.dcan.2017.09.010.
- [3] S. Li, L. Da Xu, S. Zhao, "5G internet of things: a survey," Journal of Industrial Em formação Integração, 2018. doi: 10.1016 / j.jii.2018.01.005.
- [4] Q. Wang, G. Ying, "OTN para a futura rede de transmissão", Simpósio sobre Fotônica e Optoeletrônica, 2012. doi: 10.1109 / SOPO.2012.6270500.
- [5] T. G. Robertazzi. Ótico Redes pra Telecomunicações. Introdução para Computador Networking. Springer, Cham, pp. 67-79, 2017.
- [6] YS Kavian. Sistemas Inteligentes para Projeto de Redes Ópticas: Técnicas Avançadas: Técnicas Avançadas. IGI Global, pp. 153-174, 2013.
- [7] F. Musumeci, et al., "Uma visão geral sobre a aplicação de técnicas de aprendizado de máquina em redes ópticas", IEEE Communications Surveys & Tutorials, 2018. doi: 10.1109 / COMST.2018.2880039.
- [8] J. Simmons. Projeto e planejamento de redes ópticas. Springer International Publishing Switzerland, pp. 10-15, 2014.
- [9] XS Yang. Algoritmos Metaheurísticos Inspirados na Natureza. Luniver Press, segunda edição, pp. 1-5, 2010.
- [10] A. Eira, J. Santos, J. Pedro, J. Pires, "Projeto multi-objetivo de redes DWDM de grade flexível sobreviventes", IEEE / OSA Journal of Optical Communications and Networking, vol. 3, pp. 326-339, 2014. doi: 10.1364 / JOCN.6.000326.
- [11] D. Din, "Algoritmos heurísticos e genéticos para resolver o problema de projeto de topologia virtual em redes ópticas elásticas", Journal of Information Ciência E Engenharia, vol. 33, 2017. doi: 10.1688 / JISE.2017.33.2.3.
- [12] D. Din, "algoritmo genético para projeto de topologia virtual em redes MLR WDM," Optical Switching and Networking, vol. 18, pp. 20-34, 2015. doi: 10.1016 / j.osn.2015.03.003.
- [13] SA Fernandez, AA Juan, JA Adrián, J., DG Silva, DR Terrén, "Metaheurística em sistemas de telecomunicações: projeto de rede, roteamento e problemas de alocação," IEEE Systems Journal, vol. 12, pp. 3948-3957, 2018. doi: 10.1109 / JSYST.2017.2788053.
- [14] J. Mata, et al., "Métodos de inteligência artificial (AI) em redes ópticas: Uma pesquisa abrangente," Optical Switching and Networking, vol. 28, pp. 43-57, 2018. doi: 10.1016 / j.osn.2017.12.006.
- [15] XS Yang, SF Chien, TO Ting. Computação bioinspirada em telecomunicações. Morgan Kaufmann, pp. 23-38, 2015.
- [16] C. Papagianni, et al., "Communication network design using particle swarm optimization," IEEE International Multiconference on Computer Science and Information Technology, pp. 915-920, 2008. doi: 10.1109 / IMCSIT.2008.4747351.
- [17] J. Triay, C. Cervo, "Um algoritmo baseado em formigas para roteamento distribuído e atribuição de comprimento de onda em redes ópticas dinâmicas", jornal IEEE em áreas selecionadas em comunicações, vol. 28, pp. 542-552, 2010. doi: 10.1109 / JSAC.2010.100504.
- [18] A. Rubio, MA Veja e DL González, "Uma abordagem multiobjetivo aprimorada inspirada no comportamento de flashing de vaga-lumes para Traffic Grooming em redes WDM ópticas," Applied Soft Computing, pp. 617-636, 2014. doi: 10.1016 / j.asoc.2014.03.046.
- [19] J. Pedro, "Projetando redes ópticas de grade flexível transparente para máxima eficiência espectral", IEEE / OSA Journal of Optical Communications e Networking, 2017. doi: 10.1364 / JOCN.9.000C35.
- [20] H. Liu, C. Xiong, Y. Chen, C. Li, D. Chen, "Um método de otimização de mapeamento VON para eficiência energética e roteamento em redes ópticas elásticas," Optical Fiber Technology, vol. 41, pp. 173-181, 2018. doi: 10.1016 / j.yofte.2018.01.004.
- [21] A. Eira, J. Pedro, J. Pires, "Cost-optimized dimensioning of translucent WDM networks with Mixed-line-rate spectrum-Flexible canais, "IEEE 13ª Conferência Internacional sobre High Performance Switching and Routing, 2012. doi: 10.1109 / HPSR.2012.6260848.
- [22] X. Chen, J. Admela, "Transmissão paralela otimizada em otn / wdm redes para suportar ethernet de alta velocidade com distribuição em múltiplas vias, "Journal of Optical Communications and Networking, pp. 248-258, 2012. doi: 10.1364 / JOCN.4.000248.
- [23] JR Santos, A. Eira, J. Pires, "A Heuristic Algorithm for Designing OTN Sobre Rede Flexível DWDM Networks," Journal de Communications, 2017. doi: 10.12720 / jcm.12.9.500-509.
- [24] MS Bazaraa, JJ Jarvis, HD Sherali. Programação Linear e Fluxos de rede. 4a ed., Wiley, pp. 1-35, 2010.
- [25] R. Goscien, "Duas metaheurísticas para roteamento e alocação de espectro em redes ópticas elásticas de sobrevivência prontas para a nuvem ", Swarm and Evolutionary Computation, vol. 44, pp. 388-403, 2019. doi: 10.1016 / j.swevo.2018.04.013.
- [26] R. Goscien, M. Lozano, "Artificial bee colony for optimization of redes ópticas elásticas prontas para a nuvem e com capacidade de sobrevivência ", Computer Communications, vol. 128, pp. 35-45, 2018. doi: 10.1016 / j.comcom.2018.07.011.
- [27] DT Hai, "Um modelo de programação linear inteira bi-objetivo para o problema de roteamento e atribuição de codificação de rede em redes ópticas WDM com proteção dedicada ", Computer Communications, vol. 133, pp. 51-58, 2019. doi: 10.1016 / j.comcom.2018.08.006.
- [28] KDR Assis, I. Queiroz, RC Almeida, H. Waldman, "MILP formulação para otimização de recursos em Spectrum-Sliced Elastic Optical Path Networks, "Microwave & Optoelectronics Conference (IMOC), SBMO / IEEE MTT-S Internacional, 2013. doi: 10.1109 / IMOC.2013.6646582.
- [29] A. Ghosh, S. Tsutsui. Avanços na Computação Evolutiva: Teoria e aplicativos. Springer Science & Business Media, pp. 441-461, 2012
- [30] XS Yang. Pesquisa de cuco e algoritmo de Firefly: teoria e Formulários. Vol. 516, Springer, pp. 315-331, 2013.
- [31] XS Yang, X. He, "algoritmo Firefly: avanços recentes e formulários." International Journal of Swarm Intelligence, vol. 1, pp. 36-50, 2013. doi: 10.1504 / IJSI.2013.055801.
- [32] WT Lunardi, V. Holger, "Comparative study of genetic and discrete algoritmo do firefly para otimização combinatória. " Proceedings of the 33rd Annual ACM Symposium on Applied Computing. ACM, 2018. doi: 10.1145 / 3167132.3167160.
- [33] AM Mohsen, W. Al-Sorori, "A new hybrid discrete firefly algoritmo para resolver o problema do caixeiro viajante ". Computação aplicada e tecnologia da informação. " Springer, Cham, 2017. p. 169-180. doi: 10.1007 / 978-3-319-51472-7_12.
- [34] GK Jati, R. Manurung, "Discrete firefly algorithm for travelling problema do vendedor: um novo esquema de movimento. " Swarm Intelligence e Bio-Inspired Computation. Elsevier, pp. 295-312, 2013. doi: 10.1016 / B978-0-12-405163-8.00013-2.
- [35] XS Yang, X. He, "Aplicações de algoritmos inspirados na natureza." No Mathematical Foundations of Nature-Inspired Algorithms, Springer, pp. 87-97, 2019. doi: 10.1007 / 978-3-030-16936-7_6.
- [36] DR Morrison, SH Jacobson, JJ Sauppe, EC Sewell, "Branch-algoritmos and-bound: um levantamento dos avanços recentes na pesquisa, ramificação e poda. " Otimização Discreta, vol. 19, pp. 79-102, 2016. doi: 10.1016 / j.disopt.2016.01.005.
- [37] A. Schickedanz, D. Ajwani, U. Meyer, P. Gawrychowski, "Average comportamento de caso de algoritmos de caminho mais curto k. " In International Conference on Complex Networks and their Applications, Springer, pp. 28-40, 2018. doi: 10.1007 / 978-3-030-05411-3_3.
- [38] F. Gang, "Finding k-shortest simples path in direcionado graphs: A node algoritmo de classificação. " Networks, vol. 64, pp. 6-17, 2014. doi: 10.1002 / net.21552